Comment faire une sociologie de la statistique...

par Donald MacKenzie

Les connaissances ésotériques des mathématiques passent souvent pour se développer selon leurs lois propres, à l'abri de toute influence sociale. Le but de cet article est de mettre en doute cette hypothèse en présentant une étude de cas empruntée à l'évolution de la théorie mathématique des statistiques.

L'épisode dont il s'agit est une controverse qui eut lieu en Grande-Bretagne entre 1900 et 1914. La communauté naissante des statisticiens fut divisée par une querelle sur la meilleure méthode à utiliser pour mesurer l'association statistique. Karl Pearson, l'un des fondateurs de cette communauté, et George Udny Yule, son disciple le plus connu, se trouvèrent opposés par un débat qui devint de plus en plus venimeux. L'analyse de cet épisode met en lumière les « relations sociales » de la théorie statistique en révélant les liens qui unirent

les statistiques à des problèmes idéologiques et sociaux d'ordre plus général 1.

ninant divers écrits publiés ou non de Pearson et de Inle, puis j'étendrai mon analyse aux membres de la le présenterai ensuite les autres explications possibles de montrer comment on peut relier cette exploitation a façon dont chacun évalua les positions de l'autre. Je es de la notion d'association à cause de buts différents Je commencerai par présenter les deux articles publiés en 1900 par lesquels Yule et Pearson énoncèrent pour lans les deuxième et troisième sections, j'exposerai les léveloppements qu'ils apportèrent à ces conceptions et nontrerai alors qu'il faut voir dans les jugements théoiques et scientifiques de Pearson et de Yule l'intégraion de différents « intérêts cognitifs ». Je montrerai en oarticulier qu'ils proposèrent des approches différenqu'ils poursuivaient. Je ferai ressortir ces buts en exacommunauté des statisticiens britanniques qui soutinrent l'un ou l'autre des deux principaux protagonistes. de la controverse. Enfin, je terminerai en m'efforçant divergente de la théorie statistique à des intérêts sociaux a première fois leurs conceptions divergentes. Puis,

L'objet du débat

En 1900, les statisticiens britanniques étaient arrivés à un consensus manifeste sur la façon de mesurer des

201

^{1.} Il n'existe aucune analyse complète de cette controverse. Néanmoins, Helen WALKER donne une utile bibliographie annotée des principaux articles sur le sujet dans Studies in the History of Statistical Method, Williams and Wilkins, Baltimore, Md., 1929, 130-141; et les importants articles de W.H. KRUSKAL sur les « Mesures de l'association dans les classifications croisées » contiennent une critique très complète des travaux réalisés précédemment dans ce domaine. Voir le Journal of the American Statistical Association, vol. 49 (1954), 732-764, et vol. 54 (1959), 123-163.

les il existe une échelle de mesure dotée d'une unité de variables telles que le poids ou la taille, pour lesquelmesure valable. Grâce à ses concepts de régression et de corrélation, Francis Galton avait fourni la technologie de base nécessaire au traitement de ces variables « à intervalle 2 ». F.Y. Edgeworth, S.H. Burbury et Karl Pearson avaient étendu la théorie de deux variables à un nombre quelconque, et Pearson avait élaboré la formule aujourd'hui standard des moments mixtes pour le coefficient de corrélation 3. Sauf un petit désaccord privé 4 sur le degré auquel on pouvait appliquer aux variables non normales la théorie de Galton prévue pour les variables à distribution normale, le problème semblait résolu pour les variables à intervalle. A partir de 1900, l'attention se porta sur les variables nominales — celles pour lesquelles on ne dispose d'aucune unité de mesure et qu'on ne peut que classer en catégories. Les deux principales tentatives pour élaborer une théorie de l'association des variables nominales furent celles de Karl Pearson (1857-1936) et de George Udny Yule (1871-1951).

Examinons tout d'abord les travaux de Yule. Son

2. L'utilisation dans cet article des termes « à intervalle » et « nominal » est anachronique, mais elle rend plus clair l'exposé du problème. A propos de ces termes, voir S.S. Stevens, « On the Theory of Scales of Wassurement », Science, vol. 103 (1946), 677-680. La variable est « à intervalle » lorsqu'elle est continue; elle est dite « nominale » dans le cas contraire, c'est-à-dire lorsqu'elle ne prend que des valeurs discrètes.

3. Les articles décisifs sur la question furent les suivants: F. GALTON, «Typical Laws of Heredity », Proceedings of the Royal Institution, vol. 8 of the Royal Soziety, vol. 40 (1886), 42-73; F. GALTON, « Correlations in Stature », Proceedings and their Measurement, chiefly from Anthropometric Data », ibid., vol. 45 and their Measurement, chiefly from Anthropometric Data », ibid., vol. 45 cal Magazine, Series 5, vol. 34 (1892), 190-204; S.H. Burburny, « On the Son, « Mathematical Contributions to the Theory of Evolution III: Royal Society, Series 4, vol. 187 (1896), 253-318.

approche était extrêmement directe ⁵. Soit un ensemble de N objets classés en fonction de deux variables A et B. Chaque objet est classé en A₁ ou A₂ et en B₁ ou B₂. Ainsi, A₁ peut être « survivant d'une épidémie », A₂ « mort de l'épidémie »; B₁ « vacciné » et B₂ « non vacciné ». On peut présenter les données de la façon commode suivante:

	B ₁ (vaccinés)	B ₂ (non-vaccinés)	Totaux
A ₁ (survivants)	ಇ	þ	a+b
A ₂ (morts)	o	q	c+d
Totaux	a+c	p+q	z

Dans ce tableau, « a » est le nombre de vaccinés qui ont survécu à l'épidémie, « b » le nombre de nonvaccinés qui ont survécu à l'épidémie, et ainsi de suite.

Yule estima que le coefficient d'association d'un tel tableau devait avoir trois propriétés. Premièrement, il devait être égal à zéro si, et seulement si, A et B étaient non associés ou indépendants. Dans l'exemple cidessus, la survie et la vaccination (A et B) sont dites indépendantes si la proportion des survivants est la même chez les vaccinés et chez les non-vaccinés, ce qui s'exprime de la façon symbolique suivante:

^{5.} G.U. YULE, « On the Association of Attributes in Statistics », Philosophical Transactions of the Royal Society, Series A, vol. 194 (1900), 257-319. Reimprime dans A. STUART et M.G. KENDAIL, eds, The Statistical Papers of George Udny Yule, Griffin, Londres, 1971, 7-69. Nos références concerneront cette dernière version. Dans la suite, j'ai adopté, pour des raisons de clarté, des notations standard. C'est un peu regrettable, car les notations originales de Yule et de Pearson reflétaient, dans une certaine mesure, leurs buts différents. Voir notes 6 et 7.

Yule utilisait en fait une notation légèrement différente, empruntée à la logique symbolique. Pour A₁ et A₂, il écrivait A et α, α signifiant non-A, et pour B₁ et B₂, il écrivait B et β, β signifiant non-B. Sa notation pour la fréquence « a » était (AB), pour la fréquence « b » (Aβ), etc.

i I a+c

ou: ab + ad = ab + bc

ou: ad - bc = 0

10n associés. La première condition sera donc satisfaite En faisant cet enchaînement dans l'autre sens, on beut montrer que ad - bc = 0 implique que A et B sont oar un coefficient égal à zéro si et seulement si ad - bc = 0.

être égal à +1 si et seulement si A et B sont complètement associés. On peut comprendre ici l'association ous les A₁ sont B₁ et tous les A₂ sont B₂ (c'est-à-dire La seconde propriété de ce coefficient est qu'il doit complète dans deux sens. Le premier est le sens fort: A et B sont dits complètement associés seulement si que b = c = 0). Cela veut dire en l'occurrence que tous es vaccinés ont survécu et que tous les non-vaccinés sont morts. Il y a aussi un sens faible de l'association complète: A et B sont dits alors complètement associés si soit tous les A1 sont B1, soit tous les A2 sont B2. Chacun des deux tableaux suivants représente donc une association complète au sens faible:

B ₂ (non-vaccinés)	0	p
B ₁ (vaccinés)	ಣ	၁
	A ₁ (survivants)	A ₂ (morts)

B ₂ (non-vaccinés)	q	q
B ₁ (vaccinés)	а	0
	A ₁ (survivants)	A ₂ (morts)

Dans le premier tableau, aucun des non-vaccinés ne survit (même si certains vaccinés meurent). Dans le second, aucun des vaccinés ne meurt (même si certains 10n-vaccinés survivent). Yule choisit d'utiliser cette

léfinition faible de l'association complète; son second critère fut donc que le coefficient devait être égal à +1 si et seulement si soit b=0, soit c=0.

ciation complète forte et une association complète donc complètement associés au sens négatif lorsque soit La troisième propriété du coefficient est qu'il doit être égal à -1 lorsque A et B sont complètement associés dans le sens négatif. Là aussi, nous avons une assoiaible, et Yule choisit l'association faible. A et B sont cous les A₁ sont B₂, soit tous les A₂ sont B₁.

B ₂	q	р
B ₁	0	၁
	A ₁	A ₂

B ₂	q	0	
\mathbf{B}_1	а	၁	
	Aı	A2	
-		<u></u>	

on

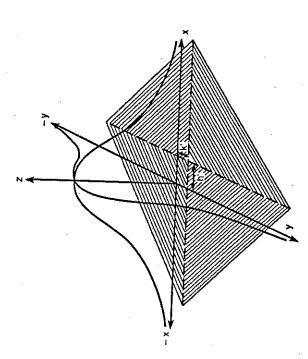
Donc le coefficient doit être égal à -1 si et seulement si soit a=0, soit b=0.

Yule examina ensuite le coefficient $Q = \frac{ad - bc}{c}$.

et donc soit a = 0, soit d = 0. Ainsi Q satisfait aux trois conditions. Yule proposa donc Q comme mesure de l'association dans les tableaux 2×2 . Mais, ainsi qu'il le savait, Q n'a pas de justification particulière. On peut trouver un nombre illimité de fonctions qui satisfont aux trois conditions de Yule, par exemple Q³, Q⁵, et ainsi de suite. En outre, comme le montra plus tard Pearson, pour ce qui concerne l'intensité de l'association, deux tableaux différents peuvent être rangés dans soit d=0, alors ad=0 et Q=-bc/bc=-1. Inversement, Q = -1 implique ad - bc = ad - bc, d'ou ad = 0ad – bc = 0, on a evidenment Q = 0. Inversement, Q = 0implique ad-bc=0. Ainsi Q satisfait à la première condition. Si soit b=0, soit c=0, alors bc=0 et ad + bc, d'où bc = 0, et donc soit b = 0, soit c = 0. Ainsi Q = ad/ad = +1. De même, si Q = +1, alors ad - bc =Q satisfait a la deuxième condition. Enfin, si soit a=0,

un certain ordre par l'une de ces fonctions et dans un ordre différent par une autre.

raisonnement théorique beaucoup plus serré mais plus périlleux, un coefficient d'association qu'il baptisa « coefficient tétrachorique de corrélation ». Je le noterai ici par r. L'hypothèse déterminante sur laquelle L'approche de Pearson consista à déduire, par un repose cette déduction de re est que l'on peut considérer le tableau 2×2 précédent comme issu du processus suivant: on estime que les catégories A1, A2 et B1, B2 correspondent à des séries de variables à intervalle plus fondamentales y et x: A1 correspondrait par exemple à $y \leqslant k'$, A_2 à y > k', B_1 à $x \leqslant h'$ et B_2 à x > h'. On suppose en outre que y et x suivent ensemble une distribulion normale à deux variables, avec x ayant pour moyenne zéro et pour écart type σ_1 , et y ayant pour moyenne zéro et pour écart type σ_2 , ce qui peut se représenter géométriquement par la figure 1.



Figure

Sur la figure 1, on voit la surface représentant la distribution en fréquence d'un couple de variables normales (en forme de cloche avec des coupes transversales elliptiques) s'élevant au-dessus du plan de x et de y. Ce plan est divisé en quatre quadrants par des lignes se croisant au point (h', k') — ces quadrants correspondant aux cases du tableau 2×2. Le volume situé audessus du sommet gauche de ces quadrants correspond à la fréquence avec laquelle x>h' et y>k', c'est-à-dire à la fréquence « a » du tableau d'origine?

Pearson avait donc fourni un modèle de distribution statistique supposé sous-jacent au tableau 2×2 . Ce modèle avait trois paramètres: h'/σ_1 , k'/σ_2 et r, la corrélation de x et y. Il y a trois paramètres dans le tableau représenté (et non quatre, car le total N est considéré comme fixe, et a+b+c+d=N). Le modèle peut s'adapter à tout tableau 2×2 , car les équations qui le relient aux observations sont toujours solubles, bien que la solution fasse appel à des méthodes numériques. On peut donc toujours trouver une valeur de r, la corrélation des variables sous-jacentes.

C'est cette corrélation des variables sous-jacentes que Pearson appela le « coefficient tétrachorique de corrélation ». Alors qu'il savait manifestement que la déduction mathématique de ce coefficient reposait sur l'hypothèse d'une distribution sous-jacente normale à deux variables et que cette hypothèse n'était pas vérifiable, il l'appela, dans le titre de son mémoire et dans d'autres écrits, la corrélation. Il envisageait certes d'autres coefficients d'association empiriques, dont le Q de Yule, mais il les traitait uniquement comme des approximations de r, présentant l'avantage d'une faci-

^{7.} PEARSON, « Mathematical Contributions to the Theory of Evolution VII: On the Correlation of Characters not Quantitatively Measurable », *Philosophical Transactions of the Royal Society, Series A*, vol. 195 (1900), 1-47. Pearson, qui voulait souligner l'analogie de r₁ avec le coefficient de corrélation ordinaire, l'appelait simplement « r ».

lité de calcul beaucoup plus grande, mais l'inconvénient de s'écarter plus ou moins de r_t.

comment faire une sociologie de la statistique...

d'aborder les développements apportés aux différentes approches. J'ai présenté les coefficients de Yule et de Pearson comme si les données auxquelles ils s'appli-Il nous reste un dernier problème à examiner avant quent étaient toujours des populations entières. A cet égard, je reste fidèle aux travaux de ces deux auteurs, qui ne faisaient pas de distinction systématique entre les statistiques calculées sur les échantillons et les paramètres associés à une population. Ces distinctions systématiques ne se répandirent qu'après les travaux de Fisher dans les années vingt. Yule et Pearson savaient le fait qu'ils calculèrent les « erreurs probables » de leurs coefficients, ils ne s'occupèrent pas vraiment des et rt étaient souvent tirées d'échantillons, mais à part bien sûr que les données auxquelles ils appliquaient Q problèmes que cela posait.

Les développements apportés aux approches de Yule et de Pearson

L'invention du coefficient tétrachorique ne servit nullement de conclusion aux travaux théoriques de Pearson sur la mesure de l'association. Ce domaine fut en 1900 et 1922. Pearson était parfaitement conscient des insuffisances de r_t — notamment le fait qu'il était limité aux tableaux 2×2. Tout en continuant à défendre l'utinesure de l'association une approche qui permette d'analyser directement les tableaux plus importants (ceux où les objets sont classés en A₁, A₂, ... A_p et B₁, incluses dans la déduction de r_t.

La plus importante de ces tentatives fut l'élaboration

constante (ce qui ne change vraisemblablement pas la force de l'association) multiplie la valeur du χ^2 par cette constante. Mais on peut facilement tourner le problème. Si on divise la valeur du χ^2 par N — le nombre manifestement pas modifié par la multiplication de chaoort aux fréquences attendues, dans l'hypothèse de 'indépendance. La valeur du χ^2 lui-même n'avait pas directement d'intérêt pour Pearson. Il voulait non pas ne peut pas servir à cette mesure, car le fait de multiplier les fréquences de chaque case d'un tableau par une total de cas du tableau —, le coefficient résultant n'est que case du tableau par une constante. Ce coefficient Pearson l'appela « contingence carrée ableaux à double entrée8. Pour tout tableau de ce ype, il est possible de calculer les fréquences attendues oles sont indépendantes et de mesurer l'écart entre les noyen du χ^2 . En se référant à la distribution du χ^2 , on de l'application de son propre test du khi carré (χ^2) aux dans chaque case dans l'hypothèse où les deux variaréquences attendues et les fréquences observées au oeut alors mesurer la probabilité de cet écart par rapmais mesurer la force de l'association. La valeur du χ^2 de la théorie de la contingence. Cette théorie découlait ejeter simplement l'hypothèse de la non-association, moyenne 9 ». $\phi^2 = \chi^2/N$

Une mesure qui repose sur χ^2 est manifestement

 $(ad-bc)^{2}$ (a+b).(c+d).(a+c).(b+d)

(a + 0).(c + c) et il ne peut être supérieur à 1.

^{8.} Le test du y' apparut pour la première fois dans K. PEARSON, « On the Criterion that a Given System of Deviations from the Probable in the Case of a Correlated System of Variables is Such that it can be Reasonably Supposed to have Arisen from Random Sampling », Philosophical Magazine, Series 5, vol. 50 (1900), 157-175.

^{9.} K. PEARSON, « Mathematical Contributions to the Theory of Evolution XIII: On the Theory of Contingency and its Relation to Association and Normal Correlation », *Draper's Company Research Memoirs: Biometric Series, I*, Dulau, Londres, 1904, 6. ϕ^2 sert encore parfois de mesure de l'association. Pour les tableaux 2×2, sa valeur est:

tableaux importants (d'environ 25 cases), car pour les

Il estimait que le meilleur usage de C1 résidait dans les

plus valable, et donc C₁ était une mauvaise estimation

petits tableaux, la relation limite entre C, et r n'était

séduisante. Elle dispense d'avoir à faire l'hypothèse de variables sous-jacentes et peut s'appliquer à toutes les tailles de tableaux. Elle est même indépendante de l'arrangement des catégories de chaque variable. Le problème qui se pose est de savoir quelle mesure particulière reposant sur χ^2 utiliser. Une fois encore, Pearson résolut le problème en revenant à la corrélation des variables à intervalle normalement distribuées. Il supposa que n'importe quel tableau était issu de la répartrouva une relation entre la contingence carrée moyenne de ce type de tableau et le coefficient de corrélation r tition de ces variables continues en catégories. Puis il

$$= \pm \sqrt{\frac{\phi^2}{1 + \phi^2}}$$

Si le tableau à double entrée provenait de la catégorisation d'une distribution normale sous-jacente à deux alors C1 approchait le coefficient de corrélation des qu'il appela « premier coefficient de contingence 11 ». variables et si le nombre des cases du tableau était élevé, variables sous-jacentes. Comme C1 est une fonction monotone de la valeur de χ^2 pour le tableau à partir duquel il est calculé, il a aussi une certaine justification en dehors du fait que ces hypothèses soient valables ou

coefficient de corrélation des variables à intervalle. des variables sous-jacentes. Dans le cas limite où le nombre des cases du tableau tend vers l'infini, il montra

1 | 1

Il proposa alors le coefficient:

 $\sqrt{1+\phi^2}$ õ ر ال

C1 ne remplaça pas r1 dans l'affection de Pearson.

11. Ibid., 9. Pearson proposa également un second coefficient de contingence basé sur une fonction différente de la divergence entre les fréquences observées et les fréquences prévues. Ce coefficient, qui était plus facile

10. K. PEARSON, op. cit., note 9, 7-8.

à calculer mais n'avait pas un rapport aussi clair avec r, fut moins uțilisé.

si elle éclaire tout le sujet... n'élimine pas l'ancienne méthode D'où le fait que la nouvelle conception de la contingence, de la corrélation des variables sous-jacentes:

rapport entre un coefficient d'association et la corrélation des variables sous-jacentes: il cherchait toujours Le critère fondamental de Pearson était toujours le un coefficient d'association directement comparable au de la quadruple division 12.

présentée en 1913 14. Ici encore on trouve comme base de la correction l'hypothèse des variables continues Les autres développements apportés à la théorie de rent en gros dans la même ligne. Le souhait que le coeflicient de contingence puisse être comparé à la corrélation des variables à intervalle se voit dans des remarques telles que celle-ci: « Afin que nos résultats s'accordent d'assez près avec les résultats d'une distrigaussienne, nous choisissons... notre échelle... 13. » L'un des grands objectifs de ces travaux était d'« améliorer » C1 par diverses corrections, dont a plus importante fut la correction de l'indice de classe 'association par Pearson et ses collaborateurs se situèsous-jacentes, et le but de la correction est d'améliorer l'estimation de la corrélation de ces variables en tenant bution

211

^{12.} K. PEARSON, op. cit., note 9, 9.

ution XVIII: On a Novel Method of regarding the Association of two Variates classed solely in Alternate Categories », op. cit., note 9, Series VII, 24. Pour un compte rendu général de ces travaux, voir K. PEARSON, ed., Tables of Statisticians and Biometricians, Cambridge University Press, 13. K. PEARSON, « Mathematical Contributions to the Theory of Evo-1914, XXXVI-XLII, LVII-LX.

^{14.} K. PEARSON, « On the Measurement of the Influence of "Broad Categories" on Correlation », Biometrika, vol. 9 (1913), 116-139.

comment faire une sociologie de la statistique...

compte du fait que C1 est calculé à partir d'un nombre fini de cases plutôt qu'à partir du nombre infini présupposé par la relation limite entre C1 et r. Sans correction, C1 tend donc à sous-estimer la « vraie » corrélation. L'effet d'une correction par l'indice de classe pour un tableau 5×5 est, par exemple, de relever C_1 d'environ 0,05.

La dernière tentative de Pearson pour trouver une solution « parfaite » au problème de la mesure de l'association fut l'élaboration d'une méthode itérative valent de r $_{t}$ pour les tableaux supérieurs à 2×2). Pearpour adapter une distribution normale à deux variables à un tableau à double entrée (en vue de trouver un équison publia une solution à ce problème dans un article qu'il cosigna avec son fils Egon en 1922 15. Mais le che de Karl Pearson, échoua, en ces temps précurseurs « coefficient polychorique » qui en résultait, même s'il représentait en un sens la conclusion logique de l'approde l'informatique, du fait que son mode de calcul était particulièrement laborieux.

Yule, lui, élabora deux autres coefficients: le « coefficient produit-somme » r_{ps} et le « coefficient de colligation » w. Ces deux coefficients ne constituaient pas une rupture fondamentale avec l'approche sur laquelle reposaient ses travaux antérieurs. Ils satisfaisaient tous deux à ses trois critères du coefficient d'association, à ciation parfaite au sens faible (soit b=0, soit c=0), r_{ps} ceci près que si Q et w prennent la valeur 1 pour l'assone prend cette valeur que pour l'association positive au sens fort (b et c = 0). Le coefficient produit-somme est le coefficient de corrélation ordinaire des variables à intervalle appliqué à un tableau 2×2 , non pas sur le mode perfectionné de Pearson, mais « naïvement », en faisant l'hypothèse que les deux catégories correspon15. K. PEARSON et E.S. PEARSON, « On Polychoric Coefficients of Correlation », Biometrika, vol. 14 (1922-1923), 127-156.

dent aux valeurs 0 et 1 d'une variable discrète. On peut montrer que cela donne la valeur suivante:

$$r_{ps} = \frac{ad - bc}{\sqrt{(a+c).(b+d).(a+b).(c+d)}}$$

Q¹⁶. Le coefficient de colligation ¹⁷ relie Q et r_{ps}. Sa Yule appelait rps « coefficient de corrélation d'un tableau 2×2 », bien qu'il ne dît pas qu'il remplacait formule est:

$$w = \frac{\sqrt{ad - \sqrt{bc}}}{\sqrt{ad + \sqrt{bc}}}$$

et Q et w sont reliés par une équation simple:

$$Q = \frac{2w}{1 + w^2}$$

trique normalisée en multipliant et en divisant les rangées et les colonnes par des constantes jusqu'à ce que chaque total marginal soit égal à 1/2N, le w du tableau d'origine est égal au rps du tableau normalisé. Donc w et rps sont aussi reliés entre eux. Mais l'interrelation de ficients de Pearson, qui se réfèrent tous à la norme O, w et rps est beaucoup plus faible que celle des coef-Lorsqu'on réduit le tableau 2×2 à une forme symé213

pendamment par le généticien W. JOHANSEN dans son livre Elementen der exakten Erblichkeitslehre, Fischer, Iéna, 1909, 272-279, et par l'anthropologue F. BoAs dans « Determination of the Coefficient of Correlation », Science, new series, vol. 29 (1909), 823-824. Pearson l'avait même déjà utilisé en 1904 sans le moindre commentaire, mais dans une situation très différente: celle de la théorie mendélienne de la transmission hérèditaire: K. PEARSON, « Mathematical Contributions to the Theory of Evolution XII: On a Generalised Theory of Alternative Inheritance, with 16. YULE introduisit pour la première fois le coefficient produit-somme in, Londres, 1911, 212-213. Ce coefficient avait déjà été proposé indéspecial reference to Mendel's Laws », op. cit., note 7, vol. 203 (1904), dans son manuel intitulé An Introduction to the Theory of Statistics, Grif-

Journal of the Royal Statistical Society, vol. 75 (1911-1912), 579-642, article reimprime dans KENDALL et STUART, op. cit., note 5, 107-170. 17. Le coefficient de colligation est introduit et discuté dans YULE, « On the Methods of Measuring Association between two Attributes »,

théorique unique du coefficient de corrélation des variables à intervalle. Q, w et r_{ps} donnent des valeurs différentes lorsqu'on les applique à un même tableau, et Yule ne proposa aucune règle générale pour indiquer le coefficient à utiliser dans tel ou tel cas.

La controverse

Le 7 décembre, Yule lut à la Royal Society de Londres aspects des deux approches concurrentes de la mesure de l'association. Cela se produisit seulement lorsque Yule fit paraître un manuel intitulé An Introduction to the Theory of Statistics 20 où il exposait ses mesures de gea pour les lecteurs de Biometrika une mise en garde Les problèmes fondamentaux en jeu dans la controverse apparurent implicitement dans les deux articles de deux articles critiquant certains aspects des travaux de Pearson et jetant en particulier le doute sur la validité ficient tétrachorique 18. Pearson répliqua à ces critiques par un article publié dans Biometrika 19. A ce stade, la controverse ne s'étendait pas encore à tous les Yule et de Pearson publiés en 1900. Pourtant, aucun des deux protagonistes n'attaquait ouvertement l'autre, et leurs relations personnelles restèrent apparemment bonnes. Le conflit ouvert ne se déclencha que fin 1905. de l'hypothèse sur laquelle reposait l'utilisation du coef-Q et rps. David Heron, collaborateur de Pearson, rédi18. YULE, « On a Property which holds good for all Groupings of a Normal Distribution of Frequency for two Variables, with Application to the Study of Contingency-Tables for the Inheritance of Unmeasured Qualities », Proceedings of the Royal Society, Series A, vol. 77 (1906), 324-336; « On the Influence of Bias and of Personal Equation in Statistics of ill-defined Qualities », Journal of the Anthropological Institute, vol. 36 (1906), 325-381.

19. PEARSON, « Reply to Certain Criticism of Mr. G.U. Yule », Biometrika, vol. 5 (1907), 470-476.

acerbe contre le « danger » des formules de Yule²¹. Puis Yule lut à la Royal Statistical Society un long article défendant sa position et attaquant celle de Pearson ²². Pearson et Heron répliquèrent par un article qui occupait 157 grandes pages de *Biometrika*²³. Cet article, paru en 1913, marqua la fin de la phase ouverte de la controverse ²⁴. Mais celle-ci ne fut pas résolue pour autant. Pearson et Yule avaient certes le sentiment d'avoir énoncé entièrement leurs positions, mais aucun d'eux n'était parvenu à convaincre l'autre, même en partie. Dans la notice nécrologique de Pearson qu'il rédigea en 1936, Yule déclara à propos de cette controverse: « Le temps résoudra la question au moment voulu ²⁵. »

Les attaques de Yule contre le coefficient tétrachorique portaient principalement sur les hypothèses qui fondaient son élaboration et son emploi. Yule écrivait en effet:

Introduire des hypothèses inutiles et invérifiables ne me paraît pas une façon souhaitable de procéder dans les travaux scientifiques 26 .

215

20. YULE, op. cit., note 16.

^{21.} D. Heron, « The Danger of Certain Formulae suggested as Substitute for the Correlation Coefficient », *Biometrika*, vol. 8 (1911-1912), 109-122.

^{22.} YULE, op. cit., note 17.

^{23.} K. PEARSON et D. HERON, « On Theories of Association », *Biometrika*, vol. 9 (1913), 159-315; la note de K. PEARSON intitulée « Note on the Surface of Constant Association », *ibid.*, 534-537 est essentiellement un supplément à cet article.

un supprentant a cet attole.

24. Sauf une exception partielle: un article écrit par Major Greenwood et Yule, dans lequel ils examinent l'utilisation du modèle normal à deux variables applique aux statistiques sur la vaccination et le déclarent non plausible: « The Statistics of Anti-typhoid and Anti-cholera Inoculations, and the Interpretation of such Statistics in general », Proceedings of the Royal Society of Medicine (Epidemiology), vol. 8 (1915), 113-190, réimprimé dans Kendall et Stuart, op. cit., note 5, 171-248.

^{25.} YULE, « Karl Pearson, 1857-1936 », Obituary Notices of the Royal Society of London, vol. 2 (1936-1938), 84.

^{26.} YULE, op. cit., note 17, 140

A propos, par exemple, des statistiques sur la vaccination (domaine auquel les biométriciens avaient appliqué la méthode tétrachorique), Yule déclarait que les catégories « vacciné » et « non-vacciné », « survivant » et « mort » étaient des classes naturellement discontinues :

morts: aucun n'est plus ou moins mort que l'autre, et les [...] tous ceux qui sont morts de la variole sont également morts sont parfaitement distincts des vivants 27.

sur l'hypothèse de variables continues sous-jacentes Appliquer dans ce domaine un coefficient qui reposait était absurde: Dans de tels cas, le coefficient normal nous donne, au mieux, une corrélation hypothétique entre des variables contrefaites 28.

Yule admettait que dans certains cas l'hypothèse ble ». Mais dans ces cas-là, l'hypothèse que la distrid'une continuité sous-jacente était « moins déraisonnasouvent utilisé le coefficient tétrachorique avec des bution sous-jacente fût une distribution normale à deux variables était fréquemment douteuse. Pearson avait tableaux 2×2 issus de tableaux plus grands par amaleut inventé le coefficient de contingence, il fut obligé de procéder ainsi, n'ayant aucune méthode d'analyse contrairement aux tableaux 2×2 , de vérifier l'hypogame des classes adjacentes. En effet, jusqu'à ce qu'il des grands tableaux. Ces grands tableaux permettaient, thèse de la distribution normale sous-jacente à deux variables.

Cela pouvait se faire de deux façons. Premièrement, si l'hypothèse était vraie, le mode d'amalgame des classes ne devait pas avoir de répercussions sur le calcul de

qu'un grand tableau était constitué selon l'hypothèse de ses finales. Yule put donc vérifier l'hypothèse de Pearun même grand tableau. Il montra que, dans certains considérablement, allant par exemple de 0,27 à 0,58 indépendante de la frontière choisie entre les deux classon en calculant r, de plusieurs façons différentes pour pour un tableau sur la ressemblance des couleurs d'yeux entre pères et fils 29. Deuxièmement, s'il était vrai Pearson, il devait posseder la propriété que Yule apper. sa valeur devait être au moins approximativement des cas cités par Pearson, les valeurs obtenues variaient lait « isotropie ».

Soit quatre fréquences adjacentes n1, n2, n3 et n4 extraites d'un grand tableau.

 ·			
	n2	n4	
	nı	n3	
Ý			
	·		

fia l'isotropie des tableaux auxquels Pearson, après Ce tableau est dit isotrope si le signe de n₁n₄ – n₂n₃ est le même pour tous les « sous-carrés » du tableau. Dans sa première critique des travaux de Pearson, Yule vériamalgame des classes, avait appliqué r,, et s'aperçut que beaucoup de ceux-ci n'étaient pas « isotropes 30 ».

pie de Yule n'était pas valable, car celui-ci avait omis d'estimer l'« erreur probable » de n₁n₄ - n₂n₃. Comme Pearson se défendit en disant que le critère d'isotro217

Yule, op. cit., note 17, 139-140.
 Ibid., 140.

^{29.} YULE, op. cit., note 17, 144. 30. YULE, « On a Property... », op. cit., note 18.

32. PEARSON et HERON, op. cit., note 23, 161, 302.

un tableau n'est que l'échantillon d'une population plus vaste, il peut y avoir une absence d'isotropie pour de simples raisons de fluctuation aléatoire. Pearson admit que les valeurs différentes de r. obtenues pour un même tableau montraient que, dans certains cas, l'hypothèse de la normalité sous-jacente paraissait inacceptable. Mais il le savait fort bien, puisqu'il avait justement inventé la méthode de contingence pour traiter ces cas-la. Lorsqu'on calculait les coefficients de contingence pour ces tableaux, ils se révélaient « sensiblement » en accord avec les coefficients tétrachoriques; Pearson estima donc que ses résultats étaient valides, malgré les défauts de la méthode qui avait permis de les obtenir 31.

L'attaque de Pearson et Heron contre l'approche de es différents coefficients de Yule prenaient des valeurs discordantes et que, pour les tableaux constitués à partir aucun ne s'accordait avec le coefficient de corrélation Yule s'appuya sur le fait que, pour un même tableau, de données normales authentiques à deux variables, Heron trouvait Q = 0.91 et $r_{ps} = 0.02$. Pour les données normales à deux variables, Q ne s'écartait pas trop du opérées près de la médiane, mais pour des divisions plus proches des queues de distributions, l'écart pouvait être grand (par exemple r = 0.5 et Q = 0.97). Avec de telles ordinaire. Pour l'un des tableaux donnés par Yule, coefficient de corrélation tant que les divisions étaient données, la valeur de Q variait exactement selon le lieu où étaient opérées les divisions; il en était de même pour rps (et, en fait, w).

Pearson et Heron estimaient que Yule réifiait ses catégories. Rares étaient les cas où il semblait justifié de recourir à de telles méthodes — comme dans la théorie de Mendel où les catégories d'un tableau 2×2 correspondaient à la présence ou à l'absence d'une unité mendélienne et où les deux variables étaient donc

authentiquement discontinues (facteur présent = 1; facteur absent = 0). Dans ces cas, r_{ps} était la façon correcte d'étendre la théorie ordinaire de la corrélation, qui supposait justement l'existence de telles variables discontinues. Mais en général, traiter ainsi les catégories relevait du pur formalisme:

Et ici, nous soulignerons immédiatement la différence fondamentale entre M. Yule et nous-mêmes. M. Yule, comme nous le montrerons plus tard, ne cesse de discuter sur le point de savoir si ses attributs sont en réalité continus ou discontinus ou cachent, sous une terminologie discontinue, de vraies variables continues. Sous des indices de classe tels que « mort » ou « guérison », « emploi » ou « chômage » de la mère, nous ne voyons que des mesures de variables continues qui, bien sûr, ne sont pas nécessairement ni a priori gaussiennes...

La controverse entre nous est beaucoup plus profonde que ne pourrait le penser au premier abord un lecteur superficiel. C'est la vieille controverse du nominalisme contre le réalisme. M. Yule jongle avec les noms des classes comme s'ils représentaient des entités réelles, et ses statistiques ne sont qu'une forme de logique symbolique. Aucune connaissance pratique n'est jamais sortie de ces théories logiques. Elles peuvent avoir un intérêt pédagogique d'exercices pour étudiants en logique, mais il s'ensuivra de grands dommages pour la pratique statistique moderne si les méthodes de M. Yule, qui consistent à traiter comme identiques tous les individus rangés sous un même indice de classe, se répandent, ce qui risque fort d'arriver, car sa voie est facile à suivre et la plupart des gens cherchent à esquiver les difficultés 32.

Pearson et Heron justifièrent la position biométrique en disant qu'elle était nécessaire pour faire au moins une hypothèse sur la nature de la distribution continue des fréquences dont les classes observées étaient des regroupements. La seule distribution qui avait été correctement étudiée sur le plan mathématique était la distribution normale. En pratique, disaient-ils, les

^{31.} PEARSON, op. cit., note 19.

méthodes fondées sur la distribution normale donnent presque toujours des résultats corrects. Le seul avantage de ces méthodes semblait être, pour eux, de résoudre les difficultés posées par ce genre de problèmes: Le coefficient de corrélation a une signification physique si précieuse et si bien définie qu'on peut l'obtenir, même approximativement, pour n'importe quel élément; il vaut infiniment plus que n'importe quel coefficient d'« association » ou de « colligation » 33.

Les intérêts cognitifs

Il serait naïf de croire, comme cela arrive parfois, que les objections soulevées dans une controverse scientifique par l'une des deux parties contre les positions de l'autre peuvent compter comme explications de cette controverse. Il faut au contraire entamer son explication en cherchant les facteurs qui décrivent correctement les façons différentes dont chaque théorie se développe et les différents critères d'évaluation des deux camps.

Je proposerai l'hypothèse que les « intérêts cognitifs » figurent parmi ces facteurs. Bien que ce terme soit emprunté à Jürgen Habermas ³⁴, je n'en déduis pas, en l'utilisant ici, que l'épistémologie stimulante mais controversée de Habermas est pleinement applicable. J'entends par « intérêts cognitifs » les aspects des applications scientifiques effectives ou potentielles d'une théorie qui produisent un effet de retour sur l'évolution de la théorie en structurant sa construction et son appréciation par les scientifiques. Il est évident que toutes les applications d'une théorie n'affectent pas le développement de la théorie, ni tous les aspects d'un ensemble, même limité, d'applications: la théorie est

différente de la pratique. De même, le terme d'« applications » ne désigne pas simplement ici les « utilisations » au sens technologique normal. Les scientifiques peuvent utiliser et utilisent effectivement les théories pour des buts entièrement internes à la science. Ce que nous voulons faire en employant l'expression « intérêts cognitifs », c'est nous concentrer sur le fait qu'il faut voir la construction et l'évaluation des théories comme une construction à des fins particulières et une évaluation qui repose sur des critères particuliers 35.

ions d'incertitude, peut être considérée, dans un sens Yule s'efforçaient tous deux d'étendre le champ de es ainsi n'est pas assez spécifique. Il n'y avait pas qu'un seul moyen « naturel » d'étendre le champ de 'analyse statistique à ce nouveau domaine; les façons différentes dont s'y prirent Pearson et Yule sont peutêtre à mettre au compte des formes concrètes différenistique des intérêts cognitifs de prévision et de maîtrise ucune technique d'inférence sûre. Mais définir les chotes sous lesquelles se manifestaient les intérêts généraux Dans un sens très général, on peut considérer que les ravaux de Pearson et de Yule exprimaient les mêmes es sciences de la nature comportent de façon caractéechnique. La théorie statistique, qui offre par exemole des techniques d'inférence utilisables dans les situagénéral, comme élargissant le champ de la prévision. En proposant des mesures de l'association, Pearson et analyse statistique à un domaine où il n'existait ntérêts cognitifs. Comme le fait remarquer Habermas, de prévision et de contrôle.

Les travaux de Pearson se référaient essentiellement à un résultat déjà acquis de la théorie statistique: la théorie de corrélation et de régression des variables à

221

^{33.} PEARSON et HERON, op. cit., note 23, 300. 34. J. HABERMAS, Connaissance et intérêt, Gallimard, 1979.

^{35.} Pour un exposé plus complet de cette notion d'« intérêts cognitifs », voir S.B. Barnes et D. MacKenzie, « On the Role of Interests in Scientific Change » in R. Wallis, ed., Rejected Knowledge, Sociological Review Monograph, 1978.

pouvait déterminer directement la valeur attendue d'une lement, la corrélation entendue dans ce sens avait été une distribution normale à deux variables. Étant donné décrire la façon dont la valeur attendue d'une variable pleinement spécifiée: celui de deux variables qui suivent le coefficient de corrélation de ces deux variables, on variable associée à une valeur quelconque de l'autre. même de la façon dont les statistiques avaient élargi le champ de la prévision. La régression était donc la théorie qui disait comment prévoir au mieux la valeur d'une variable à partir de celle d'une autre, dans les situations où il n'existait pas de correspondance terme à terme. a constante ou l'ensemble de constantes suffisants pour dépendait de la valeur d'une autre 36. Dans un cas seuintervalle. Pour Pearson, cette théorie était l'exemple La corrélation de deux variables était, pour Pearson,

L'approche de l'association des variables nominales de Pearson était manifestement structurée par l'intérêt qu'il avait à maximiser l'analogie entre l'association de ce type de variables et la corrélation de variables à intervalle ayant une distribution conjointe normale. Cette corrélation avait un sens clair pour la prévision, et ce sens en faisait le seul critère permettant d'apprécier la force de l'association. Ce point de référence fondamental fut à la base des efforts de Pearson pour construire une théorie unitaire de l'association et de la corrélation, et c'est lui qui l'amena à juger négativement les travaux de Yule.

La déduction de r_t montre qu'au début Pearson définissait l'association comme la corrélation de l'hypothétique distribution normale sous-jacente à deux variables. Dans ses travaux ultérieurs sur la contingence, cette superposition littérale des deux cas se trouva en partie rejetée: Pearson reconnaissait que l'hypothèse d'une distribution normale sous-jacente à

deux variables ne correspondait peut-être pas aux faits. Mais l'analogie continua d'opérer, comme on le voit à la façon dont le modèle normal à deux variables servit à choisir les fonctions particulières du χ^2 qui furent sélectionnées pour devenir les coefficients de contingence. Pearson considérait donc les mesures de l'association comme un moyen d'estimer la corrélation d'une distribution sous-jacente réelle ou supposée. C'était en effet tout ce que Pearson entendait par « mesure de l'association », et sa façon de présenter r₁ comme « le coefficient de corrélation » montre qu'il tenait la métaphore pour acquise. Selon lui, le critère fondamental de validité des coefficients d'association était leur utilité dans l'estimation de cette corrélation sous-jacente.

« légers » ceux qui pesaient moins. On appliquait alors de ce coefficient se rapprochait suffisamment de la corcoefficient ne s'accordaient pas avec le coefficient de comme « petits » ceux qui mesuraient moins, comme « lourds » ceux qui dépassaient 75 kg et comme à ce tableau un coefficient d'association. Si la valeur c'était un bon point en sa faveur. Si les valeurs d'un pouvait construire un tableau 2×2 en classant comme rélation des mesures discontinues de poids et de taille, suivaient une distribution normale à deux variables et 'on construisait avec ces données un tableau 2×2 ou plus grand. Par exemple, si les données concernaient la taille et le poids d'un certain nombre d'individus, on « grands » tous ceux qui mesuraient plus de 1,80 m, Ce critère de validité fonctionnait typiquement de la açon suivante: on prenait des données à intervalle qui corrélation, c'était un motif pour le rejeter.

Le coefficient tétrachorique réussissait à ce test; cette réussite était bien sûr garantie par la façon dont il était construit. Il en était de même pour le coefficient de contingence, du moins dans les tableaux suffisamment grands. En revanche, les coefficients de Yule échouaient lamentablement. Non seulement ils étaient dans

comment faire une sociologie de la statistique...

'ensemble de piètres approximations du coefficient de raires entre « grand » et « petit » et entre « lourd » et corrélation, mais les valeurs qu'ils prenaient dépenlaient du niveau où étaient opérées les divisions arbi-< léger » 37

normale, bien au contraire: il fut l'un des premiers staisticiens à attirer l'attention sur la nature non normale que sans succès, d'élaborer pour les variables non normales une théorie de la corrélation qui prenne dère comme lui que la corrélation dépend de la spécification de la fonction qui permet le mieux de prévoir 'analogie nominal/intervalle, on voit très bien le sens qu'avait pour lui l'utilisation du modèle normal à deux variables. Il n'était nullement obsédé par la distribution de nombreuses distributions empiriques et tenta, quoi-La position de Pearson était pragmatique. Si l'on consientièrement en compte leur caractère non normal 38. Vu l'intérêt fondamental de Pearson à maximiser

ciation. Ainsi, le 6 mai 1899, avant la parution du premier article sur ce ujet, il écrivit à Yule pour lui faire observer que Q ne satisfaisait pas à 93-202. Pearson en fait usage dès le tout début de ses travaux sur l'asso-37. On trouvera des exemples de ce procédé d'évaluation dans PEARon, op. cit., note 7, 15-18 et dans PEARSON et HERON, op. cit., note 23, ce test (Pearson papers, University College London, CI, D6).

ution II: Skew Variations in Homogeneous Material », op. cit., note 7, vol. 186 (1895), 343-414; « Notes on the History of Correlation », Bionetrika, vol. 13 (1920), 25-45, réimprimé dans E.S. PEARSON et M.G. KENDALL, eds., Studies in the History of Statistics and Probability, Grif-38. K. Pearson, « Contributions to the Mathematical Theory of Evoin, Londres, 1970, 185-205.

PEARSON, op. cit., note 3, 274; PEARSON, « Notes on the History of Cornales, il fallait connaître la forme particulière de leur distribution conjointe, car sans cela il était impossible de déterminer la meilleure façon quant à lui, disait qu'on pouvait utiliser pour ces variables non normales e coefficient des moments mixtes ordinaire quelle que soit la forme parais's Formulae for Regression, etc., in the Case of Skew Correlation », Proceedings of the Royal Society, Series A, vol. 60 (1897), 477-489; elation », et les lettres de 1896 entre Pearson et Yule (Pearson papers, Uni-Pearson estimait que pour aborder la corrélation des variables non norde prévoir les valeurs d'une variable à partir de celles de l'autre. Yule, iculière de cette distribution. Voir YULE, « On the Significance of Braersity College London, C1 D6).

des deux variables. Il n'y avait, selon Pearson, qu'une un modèle, Pearson estimait que le meilleur était le modèle normal à deux variables. En outre, il fallait bien l'exemple d'un coefficient non fondé sur un modèle explicite. Les valeurs de Q ne sont pas comparables des cas à intervalle en réduisant les données à intervalle de Q dépend du procédé par lequel on exécute cette d'un tableau nominal 2×2 à l'autre devient, dans cette Il faut faire une hypothèse sur la distribution conjointe seule distribution conjointe assez bien connue pour pernettre ce type d'analyse: la distribution normale à deux avait montré, disait-il, que même si l'hypothèse de la normalité n'était pas absolument juste, les inférences fondées sur cette hypothèse avaient peu de chances in modèle si l'on voulait que l'analogie nominal/intervalle ait une quelconque validité. Or le Q de Yule était avec celles du coefficient de corrélation. Et l'on ne peut vas non plus arriver à comparer des cas nominaux et à des tableaux 2×2 et en appliquant Q, car la valeur opération. En effet, la comparaison des valeurs de Q perspective, un procédé très difficile à justifier. Sans un zients d'association, Pearson estimait que l'usage de ces ariables. L'expérience qu'on avait de cette distribution d'être grandement erronées 39. Donc, s'il fallait utiliser modèle de la situation qui donne un sens aux coefficoefficients à des fins de comparaison était dangereula valeur d'une variable à partir de celle d'une autre. ement arbitraire.

a corrélation employée comme outil de prévision dans le domaine des variables à intervalle. L'approche de Yule, en revanche, était beaucoup plus souple. Un coef-L'approche de la théorie de l'association proposée 'analogie entre l'association des variables nominales et es (ou même un coefficient de corrélation dans le cas oar Pearson était donc assez étroitement structurée par icient d'association dans le cas de variables nomina-

^{39.} PEARSON et HERON, op. cit., note 23, 300.

de dépendance statistique qui ne devait satisfaire qu'à des critères formels généraux (être égal à zéro en cas maîtrise. Yule n'avait pas pour souci premier de faire de variables à intervalle), c'était pour lui une mesure utile pour résoudre les problèmes de prévision et de des inférences plus serrées que cela. Les problèmes spécifiques de prévision et de maîtrise liés à des contextes spécifiques d'application intervenaient dans son choix des coefficients particuliers (par exemple entre Q, w ou ps dans tel ou tel cas particulier), mais ne structuraient théorie qui laissait une grande place à des élaborations plus précises dans tel ou tel exemple. Il ne cherchait pas la meilleure mesure possible de l'association. De même 'association, qui donnaient des valeurs différentes pour cation concernée. Essayer d'agir ainsi en s'appuyant sur d'indépendance, à un en cas de dépendance complète, etc.). Le simple fait de savoir que deux variables sont associées (comme la vaccination et la survie) est déjà tion 40. On peut donc voir en Yule quelqu'un qui énonça une théorie formelle et générale de l'association, qu'il existe des mesures différentes d'une tendance cen-Itale (moyenne, médiane, mode, etc.), de même il y un même tableau. On ne pouvait garantir la supériorité de l'une sur l'autre avant d'avoir examiné l'applipas sa formulation globale du problème de l'associaavait, pour Yule, des façons différentes de mesurer des hypothèses sujettes à caution (comme celle des distributions sous-jacentes) était, selon Yule, dangereux et Voici les calculs et les diagrammes sur le choléra. J'y ai joint deux feuilles de réflexions sur la mesure de l'avantage, de l'efficience ou de l'efficacité de l'immunisation ou de procédès similaires. Je ne vois pas comment arriver à mesurer l'association, car les choses ne sont pas claires dans mon esprit, à commencer par ce qu'on veut mesurer avec le coefficient d'association : plus J'essaie d'y réfléchit, plus les choses s'embrouillent dans ma tête. C'est comme si je n'avais finalement besoin d'aucune mesure de l'association. L'« avantage » et l'« efficacité » me donnent ce dont J'ai besoin, et ni l'un ni l'autre n'ont la nature d'un coefficient d'association: le premier est une régression et le second Dieu sait quoi.

source d'erreurs. Yule estimait que lorsqu'on travaille sur des données nominales, il faut accepter les limites qui découlent du niveau de mesure: on a affaire à des cas classés en catégories, rien de plus. Le statisticien doit accepter les données telles qu'elles se présentent. Les méthodes de Yule étaient donc structurées par un intérêt cognitif de prévision qui l'amenait à utiliser les données nominales comme des phénomènes de plein droit; l'analogie nominal/intervalle n'avait pour lui aucune force d'évidence.

Les intérêts cognitifs différents de Pearson et de Yule rendaient leurs deux positions incommensurables 41. Les démonstrations logiques et mathématiques ne furent pas suffisantes pour décider entre les deux positions. Leurs concepts de « mesure de l'association » étaient différents: pour Pearson, il s'agissait d'estimer une corrélation sous-jacente et pour Yule de mesurer, dans un sens plus souple, la dépendance des données nominales présentées. Le même résultat mathématique se trouvait interprété différemment par les deux camps selon leurs intérêts cognitifs.

Les deux camps savaient donc qu'en principe, pour un même tableau, les trois coefficients Q, w et r_{ps} de Yule ne concorderaient pas et qu'il pouvait même y avoir entre leurs valeurs des différences quelque peu extravagantes. Aux yeux de Pearson, cela suffisait à condamner intégralement le système de Yule: comment pourrait-il en effet y avoir trois valeurs différentes de l'association pour un même tableau? Aux yeux de Yule en revanche, ce résultat correspondait parfaitement aux attentes, car Q, w et r_{ps} étaient simplement des façons différentes de résumer les données. De même, les deux

^{40.} Yule en vint en effet à douter que le coefficient d'association fût toujours ce qui convenait. Le 2 mars 1915, il écrivait à Major Greenwood:

^{41.} Sur le concept d'incommensurabilité, voir P.K. FEYERABEND, « Explanation, Reduction and Empiricism », in H. FEIGL et G. MAX-WELL, eds., Scientific Explanation, Space and Time, Minnesota Studies in the Philosophy of Science, vol. 3, University of Minnesota Press, Minneapolis, 1962, 28-97; T.S. KUHN, La Structure des révolutions scientifiques, trad. L. Meyer, Flammarion. 1983.

camps reconnaissaient que la valeur du coefficient de auquel on l'appliquait. Pour Yule, c'était là une grave contingence était affectée par la grandeur du tableau faiblesse du coefficient de contingence. Dans certaines circonstances, sa valeur reflétait le nombre des cases du tableau autant que l'association des données. Pour Pearson, en revanche, cette propriété n'était rien de moins que prévue. Le coefficient de contingence n'était égal au coefficient de corrélation que dans le cas limite donc pas étonnant que la valeur du coefficient de où le nombre des cases du tableau était infini. Il n'était contingence soit affectée par la grandeur du tableau: en faisant l'hypothèse d'une distribution normale sous-Pour prendre un autre exemple, aucun des deux camps gaussien, sa valeur différait considérablement selon le jacente, on pouvait contrebalancer cet inconvénient. données authentiquement continues issues d'un couple niveau où l'on opérait la division (par exemple entre ne contestait le fait que lorsqu'on appliquait Q aux grand et petit). Pour Pearson, cela invalidait Q. Pour Yule, les propriétés que pouvait posséder Q lorsqu'on 'appliquait artificiellement à des données à intervalle n'affectaient pas son utilisation avec des données normales puisqu'il rejetait le modèle fondamental de la

Intérêts cognitifs et finalités

division sous-jacente de Pearson 42.

Les intérêts cognitifs différents dont témoignaient les travaux de Pearson et de Yule n'étaient pas dus au hasard. On peut les relier à leurs objectifs différents concernant l'exploitation de la théorie statistique et 42. Voir YULE, op. cit., note 17, notamment 145-146 et 159-163; PEAR. Son et HERON, op. cit., note 23, notamment 171-183, 193-202; PEARSON, op. cit., note 9, notamment 8-9; PEARSON, op. cit., note 14.

comment faire une sociologie de la statistique...

peut-être fondamentalement à des intérêts sociaux différents.

Comme l'a montre Norton 43, Pearson avait des positions engagées dans le domaine de l'eugénique qui urent une motivation essentielle à ses travaux sur la théorie statistique. Dans son programme de recherche de la corrélation et de l'association jouaient un rôle à orientation eugénique, les théories de la régression, important. Le premier lien entre ces théories et l'eugéports de deux populations liées par l'hérédité. La régression était à l'origine un moyen de résumer la saçon dont les caractères attendus d'un descendant dépendaient de ceux de ses parents; Galton élabora nique avait été forgé par leur créateur, Francis Galton, qui avait élaboré la théorie de la régression et de la distribution normale à deux variables en étudiant les rappour la première fois sa distribution normale à deux Dans ses travaux sur la théorie statistique, Pearson reprit ce lien entre d'une part l'étude mathématique de variables en étudiant la distribution conjointe des caractères souches et des caractères de la descendance 44. la corrélation et de la régression, et d'autre part le problème eugénique des rapports héréditaires entre généations successives.

Dans son premier exposé général sur l'approche statistique de la théorie de l'évolution, Pearson donnait la définition opérationnelle suivante de l'hérédité:

Étant donné un organe quelconque chez un parent et le même ou tout autre organe quelconque chez ses descendants, la mesure mathématique de l'hérédité est la corrélation de ces organes pour les couples parents-descendants... Par

^{43.} Bernard Norton, « Karl Pearson and Statistics: The Social Origins of Scientific Innovation », Social Studies of Science, vol. 8 (1978), 3-34. 44. Voir les articles de Galton cités en note 3 et Ruth Schwartz Cowan, « Francis Galton's Statistical Ideas: The Influence of Eugenics », Isis, vol. 63 (1972), 509-528.

organe, on entend ici tout caractère qui peut être quantitaivement mesuré 45. Deux pages plus haut, Pearson avait expliqué que la voir la valeur de l'une à partir de la valeur de l'autre 46. Mises ensemble, ces notions d'hérédité et de était ce qui définissait la fonction permettant de précorrélation nous montrent ce que faisait Pearson : il élaborait une théorie mathématique de prévision de la descorrélation de deux variables (il parlait d'« organes ») cendance afin de prévoir, à partir des ancêtres d'un individu, les caractères de celui-ci. Galton avait résolu le problème de l'origine parentale de l'individu; Pearson voulait remonter plus loin et étudier les grandsparents, les arrière-grands-parents, etc.

L'article de Pearson révèle deux aspects de sa position sur la corrélation et sa mesure. Premièrement, on y voit que sa notion de corrélation en tant que fonction permettant de prévoir directement une variable à partir d'une autre prenait ses racines dans la tâche que la corrélation était censée remplir dans le domaine de ll ne suffisait pas de savoir que les caractères des deslait mesurer cette dépendance de façon à prévoir les la prévision de l'évolution et de la prévision eugénique cendants dépendaient des caractères ancestraux : il faleffets de la sélection naturelle ou de l'intervention volontaire dans la reproduction. Le but de Pearson était le parvenir à des conclusions telles que celles-ci:

Conformément à cette hypothèse, et avec des coefficients de corrélation aux alentours de ce qu'ils sont chez l'homme, cinq générations de sélections du type requis chez les deux parents devraient suffire à créer une race 47.

comment faire une sociologie de la statistique..

iée au rôle de cette corrélation comme mesure de la élation et l'hérédité. Pour accroître le champ des étuser de la prévision au contrôle potentiel des processus élation dans la pensée statistique de Pearson apparaît « force de l'hérédité ». En définissant l'hérédité comme a corrélation entre les parents et leur descendance, ion de l'hérédité. Il n'envisageait même pas, dans son article, que la corrélation puisse venir du fait que le Ces positions laissent également penser que le moteur des travaux de Pearson sur la théorie de la corrélation des sur l'hérédité, il fallait apporter un développement parallèle à la théorie de la corrélation. Dans cet artiele de 1896, l'association était clairement faite entre d'une part le passage de l'étude de la parenté à celui de coute la lignée ancestrale, et d'autre part le développement de la théorie de la corrélation depuis le cas à deux variables de Galton jusqu'à un nombre infini de de l'évolution, il fallait des outils de prévision précis et puissants: il ne suffisait pas d'énoncer simplement une dépendance. Deuxièmement, la prééminence de la cor-Pearson montrait le caractère aprioriste de sa concepoouvait bien être d'établir un lien direct entre la cornilieu des parents et des descendants était similaire 48, Pour aller dans la direction indiquée ici, pour pasariables.

ju'elles étaient limitées à des caractères mesurables. De des plantes, ainsi que les caractères mentaux de 'homme essentiels pour l'eugénique, n'étaient pas Le principal obstacle qui s'opposait aux études de Pearson sur l'hérédité à la fin des années 1890 était nombreux caractères tels que la couleur des animaux et directement quantifiables (cette période précédait, bien sûr, l'invention de l'échelle de l'intelligence par Binet

46. Ibid., 256-257. 47. Ibid., 317 (souligné par Pearson). 45. PEARSON, op. cit., note 3, 259.

ères des enfants et certains aspects de leur milieu familial; mais pour lui 48. Plus tard, Pearson tenta de démontrer le faible rôle du milieu en comparant les « coefficients d'hérédité » aux corrélations entre les caracc'était un problème accessoire, car il estimait que le milieu familial refléait de toute façon largement les caractères innés des parents.

comment faire une sociologie de la statistique...

comme on ne pouvait analyser les données résultantes l'hérédité de l'étude des caractères à intervalle à celle les caractères nominaux, il fallait, selon la définition opérationnelle de l'hérédité de Pearson, faire passer la dité » pour ces caractères. Pour étendre la recherche sur théorie de la corrélation de l'étude des variables à interet Simon). Tout ce qu'on pouvait faire à propos de ces caractères, c'était classer les individus en catégories, et par une théorie de la corrélation du type à intervalle, on n'avait aucun moyen d'estimer la « force de l'hérévalle à celle des variables nominales.

problème en 1900 montre que mon interprétation de La façon dont Pearson définit lui-même la nature du 'origine de ses travaux sur l'association est correcte:

ple le cas pour la peau, la fourrure ou la couleur des yeux chez les animaux ou encore de la couleur des fleurs... Or ces généralement apprécier au premier regard. L'éleveur de chela mère range les yeux de son enfant parmi les gris ou les marrons sans hésiter ni se tromper, si l'on reste dans des limites normales. Il est évident que si l'on parvient à étenà de tels cas, on aura élargi de beaucoup le champ au sein dité, de même qu'on aura réduit de beaucoup le travail de discontinue, soit continue de leur intensité. Tel est par exemcaractères sont parmi les plus communs, ceux qu'on peut dre la théorie de la corrétation pour l'appliquer facilement duquel on peut étudier numériquement l'intensité de l'héré. De nombreux caractères sont tels qu'il est très difficile, collecte des données et de constitution des informations 49. voire impossible, de constituer une échelle numérique soit vaux range une bête parmi les bruns, les bais ou les alezans;

Ces recherches sur l'hérédité non seulement furent le motif qui amena Pearson à développer sa théorie de l'association, mais encore conditionnèrent la nature de

Contributions to the Theory of Evolution VII: On the Application of Certain Formulae in the Theory of Correlation to the Inheritance of Characters not Capable of Quantitative Measurement », Proceedings of the Royal 49. K. PEARSON (avec l'assistance d'Alice LEE), « Mathematical Society, Series A, vol. 66 (1900), 324-325.

voir le lien entre d'une part ses buts de partisan de 'eugénique et du darwinisme social, et d'autre part les ation. Pearson disposait déjà de ce qu'il considérait nuler une quantité considérable de « coefficients d'hérédité ». Pour tirer le maximum des informations eur trouver un « coefficient d'hérédité » parallèle à sut donc, dans son cas, déterminé par la nécessité de naximiser l'analogie entre l'association des variables comme un moyen satisfaisant d'étudier la transmission les caractères à intervalle et il s'en était servi pour accudonner au développement de la théorie de l'association calculés pour la taille et les autres caractères du même ordre. Un coefficient d'association tel que le Q de Yule sur la transmission des caractères nominaux, il fallait celui des caractères à intervalle. Le sens qu'il fallait Pearson voulait pouvoir dire: « le coefficient d'héréne lui aurait pas permis de le faire. Comme nous 'avons déjà expliqué, les valeurs de Q ne peuvent être mentales au moyen de Q, car Q dépend de la frontière arbitraire tracée entre « grand » et « petit ». Pour que cette théorie. Dans sa définition du problème, on peut ntérêts cognitifs qui ressortent de ses travaux sur l'assonominales et la corrélation des variables à intervalle. dité des capacites mentales de l'homme est r » et comparer ce coefficient aux « coefficients d'hérédité » déjà comparées à celles du coefficient de corrélation; de même, on ne peut analyser la taille ou les capacités la comparaison nominal/intervalle fût plausible, il fallait à Pearson un coefficient qui, appliqué aux données de taille séparées en deux, donne une valeur aussi proche que possible de celle du coefficient de corrélation: d'où l'intervention de r, et le critère fondamental d'évauation des coefficients d'association 30,

de de données essentiellement nominales qui concernaient de très près l'eugénique avant même d'avoir Pearson avait en fait commencé à réunir un ensem-

^{50.} PEARSON, op. cit., note 49, 49-50.

naux tels que la couleur des yeux et sur une série de caractères mentaux nominaux tels l'« aptitude » ou le contribution majeure à la théorie de l'hérédité des rouvé, en r, le moyen de les analyser. Les corrélations parents-enfants étaient difficiles à réunir, mais Pearson raisonna en disant que la corrélation des couples de frèes et sœurs 51 avait la même valeur théorique pour mesurer la force de l'hérédité 52. Grâce à des questionnaires envoyés à des professeurs, il accumula, sur près le 4 000 couples de frères et sœurs, des observations portant sur des caractères physiques à intervalle tels que 'index céphalique, sur des caractères physiques nomicaractère « consciencieux ». L'étude avait débuté en un compte rendu complet de ses résultats lors de sa conférence à l'Anthropological Institute. Ce fut là sa caractères mentaux, et la première d'une série de tenatives plus complexes visant à montrer la prédominance de l'inné sur l'acquis 33. Ce fut aussi sa 1898; en 1903, Pearson s'estima en mesure de donner

comment faire une sociologie de la statistique...

principale tentative d'utilisation de r,, et celle qui suscita les plus vives attaques de Yule.

catégories à deux : l'une qui comprenait « intelligence rapide » et « intelligent », et l'autre le reste. Il dressa alors des tableaux 2×2 du type de celui-ci, qui concerne On peut prendre l'analyse des facultés mentales de imprévisible. « Très lourd » était par exemple défini comme: « capable de retenir dans son esprit seulement les faits les plus simples et incapable de saisir les relations entre les faits ou de raisonner sur ces relations 54 ». Pour pouvoir utiliser rt, il réduisit ces avait demandé aux enseignants de classer chaque membre des couples de frères et sœurs dans l'une des catégories suivantes: intelligence rapide, intelligent, intelligence lente, lent, lourd, très lourd et confus-Pearson comme exemple de sa façon de procéder. Il les couples de frères 55:

	l ^{er} frère		
2º frère	« Intelligent » et « intelligence rapide »	Autre	Autre Totaux
« Intelligent » et « intelligence rapide »	526	324	850
Autre	324	694	1 018
Totaux	850	1 018	1 018 1 868

Pearson tira de ces données la mesure de la « force Puis, il calcula la valeur de r₁ (en l'occurrence 0,46).

caractères physiques, et put également intégrer à la de l'hérédité » pour neuf caractères mentaux et neuf comparaison d'autres estimations antérieures de la corélation de caractères physiques chez des couples de frè-

^{51.} K. PEARSON, Life, Letters and Labours of Francis Galton, Camoridge University Press, 1914-1930, vol. 3A, 332.

varents étaient bien sûr reliées par la célèbre « loi de l'hérédité ancestrale » de Galton-Pearson. Voir K. PEARSON, « Mathematical Contributions to 52. Les corrélations des couples de frères et sœurs et les corrélations des he Theory of Evolution: On the Law of Ancestral Heredity », Proceelings of the Royal Society, Series A, vol. 62 (1898), 404-407.

nheritance of the Mental and Moral Characteristics in Man, and its Com-WELCH, « Statistics — a Vocational or a Cultural Study? », Journal of 53. Il y a trois différences essentielles entre les travaux de Pearson et es études ultérieures faites pour estimer l'« héritabilité » : l'introduction d'une échelle de l'« intelligence » numérique, l'utilisation de jumeaux aussi bien que de couples de frères et sœurs en général et l'application de modèles Si importantes que soient ces différences, on peut considérer que les traaux ultérieurs affinent l'approche fondamentale de Pearson plutôt qu'ils en écartent radicalement. La conférence de PEARSON intitulée « On the varison with the Inheritance of the Physical Characteristics » fut publiée On trouvera un point de vue intéressant sur cette conférence dans B.L. the Royal Statistical Society, Series A, vol. 133 (1970), 531-543, mais voir aussi les remarques de E.S. PEARSON, ibid., vol. 135 (1972), 143-146. multifactoriels mendéliens (en plus des simples mesures de ressemblance). lans le Journal of the Anthropological Institute, vol. 33 (1903), 179-237.

PEARSON, op. cit., note 53, 209.
 Reconstruit à partir des données complètes de PEARSON, ibid., 236.

thèses, qui n'étaient qu'en partie explicites: la comparabilité des coefficients de corrélation pour les données res et sœurs. Son raisonnement reposait sur deux hyponales; et l'interprétation de ces coefficients comme ces hypothèses, il put revendiquer une découverte remarquable: la force de la transmission héréditaire à intervalle avec la valeur de r. pour les données nomi-En outre, il déclara que le milieu ne jouait aucun rôle mesures de la « force de l'hérédité ». En s'appuyant sur pour un large éventail de caractères physiques et mensignificatif et supposa donc que les effets résiduels (le fait que la corrélation était seulement de 0,5 et non de 1) étaient simplement le produit de variations aléatoires. Pearson estimait qu'on pouvait écarter le rôle du milieu puisque sa série de caractères comprenait la coutaux était pratiquement identique et environ égale à 0,5. leur des yeux. Il était admis que le milieu ne prenait aucune part dans la détermination de ce caractère, et pourtant, la force de la transmission héréditaire pour la couleur des yeux était très proche du 0,5 propre aux autres caractères. Pearson en déduisit que si le milieu ne jouait aucun rôle dans la détermination de la couleur des yeux, il n'en jouait donc aucun dans les autres cas. Et il se prononça catégoriquement en faveur d'un rigoureux héréditarisme:

Nous sommes amenés par force, littéralement par force, à la conclusion générale que les caractères physiques et psychiques chez l'homme sont, dans de larges proportions, hérités de la même manière et avec la même intensité... Nous héritons du caractère de nos parents, de leur conscience, de leur timidité, de leurs aplitudes, de même que nous héritons de leur taille, de leur avant-bras et de leur empan 36.

A la fin de sa conférence, Pearson tirait les conclusions qui découlaient de son analyse. Il parlait de l'inaptitude des Britanniques à soutenir la concurrence

comment faire une sociologie de la statistique...

impérialiste avec l'Allemagne et les États-Unis et de la cause de cette inaptitude: le manque d'intelligence et d'esprit de commandement. Il déclarait que ses travaux montraient que la seule solution était de « modifier la fécondité relative des bonnes et des mauvaises souches de la communauté »:

Ce remède consiste d'abord à faire prendre conscience à la fraction intellectuelle de notre pays qu'il est possible de soutenir et de former l'intelligence, mais qu'aucune formation ni aucune instruction ne pourra la *créer*. Il faut la produire, tel est le résultat général sur lequel doit s'appuyer l'art de gouverner, et qui découle de l'égalité de la transmission des caractères psychiques et physiques chez l'homme ⁵⁷.

Étant donné le souci d'« efficacité nationale » de l'époque, ces paroles ne pouvaient mieux tomber, et elles ne manquèrent pas de retentir en dehors de la communauté scientifique. La conférence de Pearson fut longuement citée par le Comité départemental sur la détérioration physique institué par le gouvernement dans la frayeur qui suivit les premières défaites britanniques contre les Boers en Afrique du Sud ³⁸. Peu de contemporains de Pearson auraient pu comprendre entièrement l'élaboration mathématique de son coefficient tétrachorique et peu semblent avoir examiné de près son raisonnement, mais la conclusion qu'il en tirait frappa juste.

Yule en revanche n'avait pas d'engagement par rapport à l'eugénique. On ne lui connaît aucune déclaration publique à ce sujet, et rien dans sa correspondance avec Pearson par exemple ne révèle ses opinions. Toutéfois, dans les lettres qu'il échangea avec celui qui fut peut-être son meilleur ami, Major Greenwood, on

56. PEARSON, op. cit., note 53, 204.

^{57.} PEARSON, op. cit., note 53, 207 (souligné par Pearson).

Report of the Inter-Departmental Committee on Physical Deterioration. Londres, HMSO, 1904, Cd. 2175, 38-39. Sur le contexte général, voir G.R. SEARLE, The Quest for National Efficiency, Blackwell, Oxford, 1971.

trouve quelques éléments sur ses opinions personnelles. Elles semblent faites d'un mélange d'indifférence et d'hostilité, comme le montrent les citations suivantes: [...] je trouve le vote des femmes aussi répugnant que 'eugénique.

tion indépendante de son professeur 62. En 1893, Yule âgé de 22 ans, devint l'assistant de Pearson chargé des

ravaux pratiques et le seconda dans son enseignement

des mathématiques aux futurs ingénieurs -- tout en constituant avec Alice Lee l'auditoire de son premier cours de statistiques mathématiques 63. En 1895, il fut élu à la Royal Statistical Society, dont il devint un membre actif, alors que Pearson, premier statisticien du pays, n'en fit jamais partie. Ce sont les préoccupa-

son, Yule montrait déjà qu'il évoluerait dans une direc-

Même lorsqu'il n'était encore que l'étudiant de Pear

comment faire une sociologie de la statistique...

Ce Congrès de l'eugénique ressemble à une farce...

Society me demandant de faire des conférences. Ceia ne me Je viens de recevoir la lettre de l'Eugenics Education plaît pas du tout...

Je ne suis pas eugéniste et l'eugénique ne m'intéresse pas le moins du monde 59. Lorsque son travail universitaire touchait à des sujets vis des positions eugéniques de l'époque. Sur le proeugéniques, Yule affichait une certaine distance vis-àblème hérédité contre milieu, il se montrait prudent:

son qui fournirent le contexte d'application d'une bonne partie des travaux statistiques de Yule. Fondée

en 1834, la Statistical Society n'avait pas montré grand intérêt pour le développement de la méthode statistique tratives et officielles, sur les données relatives à des

domaines tels que les finances, les salaires, le paupé-

risme, la criminalité, les vaccinations et les épidémies.

Abrams présente ainsi cette société:

et s'était plutôt concentrée sur les statistiques adminis-

conservatrice — et non le darwinisme social de Pear-

tions de cette auguste maison -- auguste mais plutôt

Pour prendre un exemple concernant la transmission des maladies, les chances qu'un individu a de mourir de phtisie dépendent non seulement du caractère phtisique de ses ancêtres, mais aussi très largement de ses habitudes, de son éducation et de sa profession 60.

nistes voyaient un symptôme de dégénérescence héréditaire. Mais Yule, esquivant ce genre de discus-L'un des grands sujets des premiers travaux statistiques de Yule fut le paupérisme, dans lequel les eugésion, s'intéressa à la façon dont les réformes des gouvernements, notamment la suppression de l'assistance, réduisaient le taux observé de paupérisme 61.

60. G.U. YULE, « Mendel's Laws and their Probable Relations to

59. Yule à Greenwood, 3 avril, 8 août, 8 novembre 1912 et 17 août 1920.

Lettres en possession de G.B. Greenwood.

tion of Out-Relief », Economic Journal, vol. 5 (1895), 603-611, vol. 6

61. G.U. YULE, « On the Correlation of Total Pauperism with Propor-(1896), 613-623; « Notes on the History of Pauperism in England and Wales from 1850, treated by the Method of Frequency Curves; with an Introduction on the Method », Journal of the Royal Statistical Society, vol. 59 (1896), 318-349; « An Investigation into the Course of Pauperism in England, chiefly during the last two Intercensal Decades », ibid., vol. 62

Intra-Racial Heredity », New Physiologist, vol. 1 (1902), 228.

membres principaux, ceux qui avaient le plus d'expérience blait plutôt à une sous-commission de cabinet travailliste. Ses dans la recherche statistique intensive, étaient essentiellement ser son action accentuèrent le style des travaux auquel la société était déjà prédisposée, c'est-à-dire l'accumulation de Dans ses premières années, le Conseil de la société ressemdes fonctionnaires du gouvernement. Et le désir de servir, de conseiller, d'influencer le gouvernement et de rationali-

(1899), 249-286.

Udny Yule, CBE, FRS », Journal of the Royal Statistical Society, Series « George Udny Yule, 1871-1951 », Obituary Notices of Fellows of the Royal Society, vol. 8 (1952-1953), 309-323, et M.G. KENDALL, « George A, vol. 115 (1952), 156-161, réimprimé dans KENDALL et STUART, op. cit., 62. On trouvera des détails biographiques sur Yule dans F. YATES, note 5, 1-5.

^{63.} Je remercie le professeur E.S. Pearson de m'avoir permis de consulter les notes relatives à ce cours.

comment faire une sociologie de la statistique..

faits systématiquement détachée de toute spéculation fondamentale sur leur signification 64. Si techniquement les travaux de Yule étaient bien en ayance sur les habitudes de la Statistical Society, leur objet, leur forme et même leurs hypothèses politiques en étaient très proches. Les sociétaires étaient donc habitués aux travaux orientés vers la diminution du paupérisme et le fait que Yule s'intéressât aux structures administratives plutôt que sociales et économiques ne les déconcertait pas, même si son appareillage technique était neuf.

Il se peut que Yule en soit arrivé à concevoir la nécessité d'une mesure de l'association en étudiant un autre sujet favori de la Royal Statistical Society: les statistiques sur la vaccination. En 1897, lors d'une discussion à la société sur un article antivaccination, il fit un long commentaire très critique sur les techniques statistiques utilisées par l'auteur 65. Ce qui l'amena à chercher une mesure standard de l'association entre la vaccination et la survie en cas d'épidémie fut peut-être le fait que, dans les débats sur la vaccination qui faisaient rage à l'époque, les statistiques étaient souvent utilisées de façon douteuse 66. Bien que ses intérêts cognitifs d'amélioration des statistiques sur la vaccination aient certainement joué un rôle dans la façon dont il structura ses travaux sur l'association 67, ils ne le poussè-

64. P. ABRAMS, The Origins of British Sociology, 1834-1914, The University of Chicago Press, Chicago, 1968, 15.

65. Journal of the Royal Statistical Society, vol. 60 (1897), 608-612. L'article critiqué par Yule était celui d'A. Milnes, « Statistics of Small-Pox and Vaccination, with Special Reference to Age-Incidence, Sex-Incidence and Sanitation », ibid., 552-603.

66. Sur les débats concernant la vaccination, voir R.M. MACLEOD, « Law, Medicine and Public Opinion: the Resistance to Compulsory Health Legislation, 1870-1907 », Public Law (été 1967), 107-128; (automne 1967), 189-211.

67. Lorsqu'on mesure l'association entre la vaccination et la survie et qu'on veut faire des comparaisons, il est évidemment souhaitable d'avoir

une mesure qui soit indépendante de la virulence de l'épidémie (propor-

olus des contraintes souples à l'évaluation des mesures le l'association. Il fallait par exemple trouver une vention totalement sans effet (pas d'association) et une laborer ses coefficients d'association, qu'il ait adopté me approche théorique empirique plutôt qu'unitaire et qu'il ait préféré traiter les données nominales telles comme propriété exclusive des données. Les exigences iées au problème de la vaccination imposaient tout au convention qui permette de distinguer entre une inter-Mais il n'était pas nécessaire de procéder à des inférenisé des critères de forme plutôt que de substance pour quelles, tout cela s'éclaire lorsqu'on prend en considéent pas à chercher une mesure unique de l'association ses inductives plus générales. Le fait que Yule ait utintervention totalement efficace (association complète) ration cette situation.

Mais il ne faudrait pas dire que Yule élaborait une théorie générale de l'association et Pearson une théorie n'ayant qu'un champ limité d'application. Pearson était convaincu que sa théorie était générale, et il l'appliqua même aux cas préférés de Yule tels que les statistiques sur la vaccination; Yule critiqua violemment l'application de la théorie de Pearson aux données de la transmission héréditaire 68. Chaque camp considérait que la théorie de l'autre était fausse et non pas simplement appliquée à tort. Il faudrait plutôt dire que les buts spécifiques de Pearson l'amenèrent à élaborer une théorie complexe et perfectionnée qui embrassait des intérêts cognitifs spécifiques, alors que les buts plus diffus de Yule l'amenèrent à élaborer une

tion totale des cas entrant dans les colonnes « survivant » et « mort ») et du degré d'activité des autorités médicales (proportion des vaccinés et des non-vaccinés). Yule chercha donc à élaborer des coefficients que ne modifient pas la multiplication d'une rangée ou d'une colonne par une constante. Voir YULE, op. cit., note 17, 113-123.

^{68.} PEARSON, op. cit., note 7, 43-45; YULE, op. cit., note 17, et « On a Property... », op. cit., note 18.

théorie plus floue et plus empirique, qui embrassait des intérêts cognitifs plus généraux.

Autres aspects de la controverse

s'agissait simplement d'une querelle entre deux individus, Pearson et Yule. Bien qu'ils aient été de loin les protagonistes les plus actifs du débat, il est important d'examiner la participation des autres membres de la communauté statistique britannique. Le groupe des scientifiques qui contribua à développer la théorie sta-Jusqu'ici, j'ai abordé la controverse comme s'il tistique en Grande-Bretagne entre 1900 et 1914 était restreint. En établissant une liste à partir de la Bibliography of Statistical Literature de Kendall et Doig et en vérifiant dans les revues, la correspondance et divers autres documents de l'époque, on arrive à vingtque 69. Douze d'entre elles peuvent être considérées comme des membres de l'école biométrique de Pearson sonnels, avec les Biometric and Eugenic Laboratories six personnes dont on peut dire qu'elles s'intéressaient activement au développement de la théorie statistien raison de leurs liens étroits, institutionnels ou perde l'University College de Londres, et du fait que leur support de publication préféré semblait être la revue Biometrika. Les quatorze autres avaient des appartenances diverses: il y avait des fonctionnaires, des mem-

69. Cette liste ne comprend pas ceux qui n'écrivirent qu'un seul article sur la question et ne semblent donc pas s'y être activement et longtemps intéressés. Le problème essentiel de sélection est évidemment de savoir si tel travail apporte un développement à la théorie ou à la méthode statistiques ou s'il n'est qu'une application des méthodes existantes. Ainsi Spearman fait partie de la liste, mais Burt en est exclu; si cette discrimination suppose de réelles différences dans la nature de leurs travaux, elle montre aussi qu'il n'y a pas de division absolue entre ceux qui font partie de la liste et ceux qui en sont exclus.

comment faire une sociologie de la statistique...

bres de l'Université, et un scientifique employé dans ?industrie 70.

Heron), soit contribuèrent aux discussions théoriques et aux développements de l'approche pearsonienne (Bla-Soper), soit utilisèrent le coefficient tétrachorique dans Sur les douze membres de l'école biométrique, dix soit prirent part aux attaques contre Yule (Pearson et keman, W.P. Elderton, Everitt, Heron, Pearson, Snow, aux deux autres (Galton et Isserlis), je n'ai pas trouvé des travaux empiriques (E.M. Elderton, Lee, Schuster d'éléments sur leurs positions. Galton mourut en 1911, mençait juste ses travaux sur la théorie statistique à la que et ses développements ultérieurs faisaient partie de et tous les précédents sauf Blakeman et Soper). Quant avant que la controverse fût résolue, et Isserlis comfin de cette période. Cette situation correspond en gros à ce qu'on pourrait attendre. La méthode tétrachori-'approche caractéristique de l'école biométrique, surtout en eugénique, et constituaient le centre des étaient largement appliqués aux données empiriques, réflexions théoriques de cette école.

Pourtant, les membres de l'école biométrique n'étaient pas tous des eugénistes convaincus. Certains l'étaient, tel David Heron (1881-1969), le principal allié de Pearson dans les attaques contre Yule, qui semble quitté le groupe des biométriciens 71. Mais l'exemple avoir gardé ses convictions eugénistes même après avoir de Yule montre qu'on pouvait très bien rester long-

^{70.} Je classerai parmi les membres de l'école biométrique les individus Galton, D. Heron, L. Isserlis, A. Lee, K. Pearson, E.H.J. Schuster, E.C. Snow, H.E. Soper. Les « autres » sont: A.L. Bowley, J. Brownlee, F.Y. Edgeworth, R.A. Fisher, W.S. Gosset, M. Greenwood, R.H. Hooker, J.M. suivants: J. Blakeman, E.M. Elderton, W.P. Elderton, P.F. Everitt, F. Keynes, G.J. Lidstone, A.G. McKendrick, W.F. Sheppard, C. Spearman, G.H. Thomson, G.U. Yule.

^{71.} Voir les remarques qu'il fit en présentant un article de Leonard DARWIN, Journal of the Royal Statistical Society, vol. 82 (1919), 27-29. Sur la carrière de Heron, voir la notice nécrologique de E.S. PEARSON, bid., vol. 133A (1970), 287-290.

comment faire une sociologie de la statistique...

était un groupe cohérent de gens étroitement liés 72 lemps membre actif du groupe des biométriciens sans Ce groupe fut pendant plus de trente ans le haut lieu Grande-Bretagne. Il attira donc des gens qui voulaient recevoir une formation statistique, sans partager forcément les opinions de Pearson. Néanmoins, si l'on faut déplacer son attention des motifs individuels aux partager la position dominante à l'égard de l'eugénique. de l'enseignement et de la recherche statistiques en plutôt que comme un simple agrégat de personnes, il activités de recherche institutionnalisées du groupe et aux intérêts qui en découlaient. L'école biométrique financé en grande partie par ses activités de recherche nées, les développements de la théorie mathématique considère l'école biométrique comme un groupe social d'équipe qui intégrait étroitement la collecte de donen eugénique 73. Cette recherche était un travail

72. On voit dans la satire suivante que les adversaires de r, se sentaient face à un groupe cohérent;

Extrait du Times du 1er ayril 1925:

George Udny Yule, condamné pour haute trahison le 7 mars dernier, a été exccuté ce matin sur un échafaud dressé en la gare de Gower Street. Une scène brève mais pénible s'est déroulée sur l'échafaud. Alors qu'on ajustait la corde, le criminel fit une remarque qui ne fut qu'imparfaitement entendue dans l'enceinte de presse; les seuls mots audibles furent en effet: « le coefficient normal est... » l'ule sut immédiatement saisi par le garde impérial et bâillonné. Puis le jury du reau, et parmi les personnalités présentes se trouvaient le Shérif, le vicomte Heron coroner constata que la mort avait été instantanée. Snow faisait office de bourof Borkham et l'honorable W. Palin Elderton,

chemin dans une agitation indescriptible jusqu'au lieu de l'incident, mais l'un A l'heure où nous mettons sous presse, le mandat d'amener contre Greenwood n'a toujours pas été délivré, mais la police dispose d'un indice qu'elle estime important: au cours du service habituel du matin, suivi par de nombreux fidènelles: « Je crois en un seul coefficient de quadruple corrélation saint et absolu », un homme à l'aspect misérable, debout près de la porte nord, s'écria: « Mon c... » Les bedeaux, armés de nombreux volumes de Biomerrika, se frayèrent un d'eux survagement mordu au mollet par un chien bâtard et, dans la consules, en la cathédrale Saint-Paul, le chœur, conformément au décret impérial, entonnait le credo carolingien. Soudain, alors que retentissaient les paroles solension, le criminel parvint à s'échapper.

nics Movement, 1865-1925 » (thèse de doctorat non publiée, Indiana University, Bloomington, 1970), donne la composition des subventions et du L.A. FARRALL dans « The Origin and Growth of the English Eugepersonnel des Biometric and Eugenic Laboratories.

penser qu'il y avait un rapport entre les nécessités de a recherche eugénique et les intérêts cognitifs de dévement des motifs personnels des membres de l'école. Je itt, qui dressa les tableaux des fonctions tétrachoriques permettant de calculer plus facilement 11, partageait les vaillait à résoudre une difficulté surgie dans le contexte oppement de la théorie de l'association, indépendamn'ai pas réussi à découvrir si, par exemple, P.F. Eveopinions de Pearson. Il n'en reste pas moins qu'il trad'un programme de recherche intégré où les exigences de la recherche eugénique suscitaient des problèmes indispensable, les calculs, etc., sous le contrôle personnel de Karl Pearson 74. On peut donc raisonnablemen echniques particuliers, et en conditionnaient la solu-

1880-1949). Dans son cas, on observe trois évolutions Un seul statisticien important quitta l'école biomérique durant cette période: Major Greenwood varallèles entre 1910 et 1914. Il quitta le groupe des chercheurs directement réunis autour de Karl Pearson icien au Lister Institute of Preventive Medicine 15; il à l'University College pour prendre un poste de statissemble qu'à la suite peut-être de cette entrée dans un nouveau domaine universitaire qui, par tradition, insisniques 76. Et de partisan enthousiaste du coefficient tétrachorique (qu'il décrivait, dans un article de 1909 culose, comme la méthode quadruple « exacte » et adopté une position critique vis-à-vis des doctrines eugésur l'importance du facteur héréditaire dans la tubertait sur les causes des maladies liées au milieu il ait

^{74.} Voir E.S. PEARSON, « Karl Pearson. An Appreciation of some Aspects of his Life and Work », 11e partie, Biometrika, vol. 28 (1936), 193-257, et 2e partie, ibid., vol. 29 (1937-1938), 161-248.

^{75.} La carrière de Greenwood est présentée dans L. Hogben, « Major Greenwood, 1880-1949 », Obituary Notices of Fellows of the Royal Society, vol. 7 (1950-1951), 139-154.

ment, un adversaire de r. Il serait impossible, avec les éléments dont on dispose, d'établir un rapport de cause à effet entre ces processus; pourtant l'exemple de « vraie »), il devint, d'abord en privé, puis ouverte-Greenwood nous incite à relier ensemble l'appartenance nique et l'utilisation de la méthode tétrachorique ou des à l'école biométrique, les travaux scientifiques en eugéautres techniques pearsoniennes 77.

Qu'en était-il à présent des statisticiens qui ne fai-Brownlee, semble avoir été un partisan enthousiaste de la méthode tétrachorique. Il appartenait à la section de saient pas partie de l'école biométrique? Un seul, John Glasgow de l'Eugenics Education Society 78. A part Yule, Greenwood et Brownlee, seuls deux statisticiens Society et c'est lors d'une des réunions de celle-ci qu'ils « non biométriciens » semblent avoir pris publiguement position sur la mesure de l'association: F.Y. Edgeworth et R.H. Hooker. Aucun des deux, que je sache, n'était apportèrent un soutien au moins réservé à Yule 80: il eugéniste 79. Ils étaient membres de la Royal Statistical

demiology), vol. 2 (1909), 259-268. Les critiques grandissantes de Greenwood sont formulées dans ses lettres à Yule et dans GREENWOOD et nary Tuberculosis », Proceedings of the Royal Society of Medicine (Epi-77. M. Greenwood, « The Problem of Marital Infection in Pulmo-YULE, op. cit., note 24.

tion of the Correlation Coefficient to Mendelian Distributions », Biome-78. Eugenics Education Society, Annual Reports (1910-1911, 1911-1912). Sur la vie de Brownlee, voir M. GREENWOOD, « Obituary: vol. 90 (1927), 405-407. Brownlee utilisa même r. dans le cadre de la théorie BROWNLEE, « The Significance of the Correlation Coefficient when applied to Mendelian Distributions », Proceedings of the Royal Society of Edinburgh, vol. 30 (1909-1910), 473-507; E.C. SNOW, « The Applicamendélienne, où les biométriciens le jugeaient inapplicable. Voir J. John Brownlee, MD, DSc », Journal of the Royal Statistical Society, trika, vol. 8 (1911-1912), 420-424.

79. EDGEWORTH, dans Mathematical Psychics, Kegan Paul, Londres, montré beaucoup de sympathie pour l'eugénique. Quant à Hooker, je n'ai 1888, utilisait bien les idées héréditaristes contre l'environnementalisme égalitariste des utilitaristes radicaux, mais à part ce livre, il ne semble pas avoir rouvé aucun écrit de lui sur l'eugénique.

80. Voir ses commentaires sur l'article de Yule cité note 17 dans le Journal of the Royal Statistical Society, vol. 75 (1911-1912), 643-644 et 646-647.

d'une revue, mais au moins elle prêta à Yule une oreille avorable et lui permit de publier son attaque majeure assuraient leurs propres publications et disposaient semble en fait que, pour Yule, cette société ait été ce qui s'approchait le plus d'une « base institutionnelle ». Elle ne pouvait manifestement se comparer en rien aux Biometric and Eugenic Laboratories de Pearson, qui contre Pearson, ainsi que d'autres écrits moins imporants sur l'association.

che de Pearson était liée aux impératifs de la recherche eugénique et celle de Yule aux impératifs plus ou moins Ainsi, l'étude des statisticiens britanniques autres que tation, il nous faut considérer les autres explications Pearson et Yule confirme dans l'ensemble que l'approspécifiques d'une statistique d'application générale. Mais, avant de passer au stade final de notre argumenpossibles de la controverse et examiner brièvement l'histoire de la mesure de l'association après 1914.

On pourrait dire que les conceptions philosophiques de Pearson expliquent sa façon de considérer la mesure de l'association. Pourtant son approche -- qui repose sur l'utilisation de variables sous-jacentes hypothétiques - semble contredire plutôt qu'illustrer le programme positiviste et phénoménaliste exposé dans The Grammar of Science 81. Les exigences pratiques de ses recherches se révélèrent plus fortes que sa stricte phiosophie des sciences. Alors qu'il caractérisait le débat comme un affrontement entre son « nominalisme » et concerne leurs conceptions respectives de la corrélation, que c'était Pearson le « réaliste » et Yule le « nominaiste ». L'argument développé par Pearson dans sa conférence de 1903 repose par exemple sur une interprétation de la corrélation comme mesure d'une entité le « réalisme » de Yule 82, on peut dire, en ce qui éelle — la force de l'hérédité — interprétation qui

Londres, Walter Scott, 1892.
 Ibid., p. 47.

comment faire une sociologie de la statistique...

s'effondre en grande partie si la corrélation devient simplement le nom donné à un ensemble de données soumis à l'examen 83. L'inclination cosmologique générale en partie le fait qu'il ait rejeté des méthodes telles que rps (qui traitaient les individus d'une même catégorie ble, expliquer les caractères particuliers de sa méthode de Pearson pour la continuité et la variation plutôt que l'homogénéité et les entités distinctes 84 peut expliquer comme identiques en un sens), mais ne peut, il me semde mesure de l'association. En tout état de cause, il vaut pratique scientifique (en l'occurrence la pratique de peut-être mieux considérer ce genre de position cosmologique globale comme une généralisation tirée de la Pearson en tant que statisticien spécialisé dans la biologie et l'eugénique) que comme des facteurs déterminant de façon indépendante cette pratique.

Les explications psychologiques (telles que le conflit ment détériorées à la suite de leur désaccord, et non le Les relations entre Pearson et Yule se sont manifestede deux personnalités) ne semble pas convenir non plus. contraire 85. Leurs divergences de vues transparaissaient déjà dans leurs articles tout à fait amicaux de 1900. Même si Pearson et Yule étaient restés les meilleurs amis du monde, ils auraient malgré tout mesuré 'association différemment, et il aurait fallu malgré tout expliquer cette différence.

Une troisième explication possible serait de dire que

84. B. Norton, « Biology and Philosophy, the Methodological Foun-

The Grammar of Science, op. cit., note 81, p. 56-58.

dations of Biometry », Journal of the History of Biology, vol. 8 (1975),

85. Tel fut le compte rendu que fit Yule à Greenwood (lettres des 18

et 26 mai 1936, archives Yule, Royal Statistical Society, box 2). La correspondance entre Yule et Pearson confirme cet état de fait : elle se pouren 1905, puis s'arrête brusquement (à l'exception de trois lettres en 1910 sur une affaire personnelle). Cette correspondance se trouve dans les Pear-

suit sur un ton amical jusqu'à la première attaque de Yule contre Pearson

son papers, University College, Londres, C1 D3 et C1 D6.

mission héréditaire » chez d'autres individus que Pearson l'amenèrent autant sinon plus que les autres à élaborer la méthode tétrachorique. Il est exact que homme. Mais isoler une biométrie « neutre » d'une eugénique « idéologique » serait contraire à l'histoire les préoccupations biométriques non eugéniques de Pearson utilisa r1 pour mesurer la « force de la transet empêcherait de saisir la pensée de Pearson dans son l'hérédité chez les plantes et les animaux étaient utilihumains à celle des animaux). Les travaux biométriques quantifier la théorie de l'évolution et la rendre à la fois intégralité. Les résultats des études biométriques sur sés dans les argumentations eugéniques (on comparait par exemple la force de l'hérédité des caractères de Pearson furent de toute façon une tentative pour igoureuse et applicable à l'homme. C'était une entreprise sociale et politique:

ion intellectuelle passive de la nature, elle s'applique à homme en société comme à toutes les formes de vie. Elle nous enseigne l'art de vivre, de bâtir des nations stables et dominantes, et elle est aussi importante aux hommes d'État et aux philanthropes dans leurs délibérations qu'au savant La théorie de l'évolution n'est pas simplement une concep dans son laboratoire ou au naturaliste sur le terrain 86.

sèrent pratiquement à l'époque de la Première Guerre se réduisit sensiblement. « Les années d'après guerre ne mondiale. Deux facteurs y ont probablement contribué. Après 1918, l'énorme quantité de données sur la transaffluait dans les Biometric and Eugenic Laboratories furent pas favorables à la diffusion du credo eugéni-Comment se termina la controverse? Les débats cesmission des caractères chez l'homme et les animaux qui que de Galton » et, dans les travaux de Pearson,

^{86.} K. PEARSON, The Grammar of Science, Adam and Charles Black, Londres, 2° édition, 1900, 468.

Pearson, et le nombre des travaux théoriques et pratiques faits par son laboratoire sur la mesure de l'assothéorie statistique, grâce notamment aux travaux de R.A. Fisher, approche qui orienta l'attention vers des eugéniste convaincu, mais il ne mélangeait pas ses opinions eugénistes et ses recherches statistiques, et les « l'eugénique fut provisoirement mise de côté 87 ». ciation diminua considérablement. En second lieu, on assistait à la naissance d'une nouvelle approche de la problèmes différents. Fisher était, comme Pearson, un nnovations décisives qu'il apporta à la théorie statisconvictions eugénistes. Étant mendélien, il avait une l'importance directe du problème s'affaiblit donc pour tique furent motivées par des exigences d'expérimentation, notamment en agriculture, plutôt que par ses approche de l'hérédité différente de celle de Pearson, sant la variance à partir d'un modèle théorique mendélien plutôt qu'en comparant les coefficients de corrélation 88. Bien qu'il ne rejetât pas les travaux de et il chercha à mesurer la force de l'hérédité en analy-Pearson sur la transmission des caractères mentaux, son propre programme de recherche le conduisit plus loin sans qu'il eût besoin de recourir aux coefficients d'association.

lue. Le courant statistique de l'époque adopta une Mais la controverse n'en fut pas pour autant résovision pluraliste de la mesure de l'association en refusant d'accorder une validité exclusive à l'un des coefficients en particulier. Dans les travaux de Goodman et Kruskal, qui eurent un grand retentissement, il est dit que les mesures « doivent être faites soigneusement d'une manière adaptée au problème considéré⁸⁹ »,

Society. 87. E.S. PEARSON, op. cit., note 74, 2° partie, 205, 206. 88. Voir B. Norton, « Fisher and the neo-Darwinian Synthesis », article lu à l'International Congress of the History of Science, Édimbourg,

chez les sociologues 90. Le coefficient tétrachorique de donc plus voisine de celle de Yule que de celle de Pear-Pearson, en revanche, a presque disparu, sauf dans les travaux psychométriques 91. Il serait intéressant de se fait que d'une part la majorité des statisticiens actuels afin qu'on puisse en tirer des interprétations opérationnelles. L'approche générale des statisticiens actuels est son. Le coefficient Q de Yule reste populaire, surtout demander si l'on pourrait attribuer cette situation au partagent l'absence générale d'orientation vers des buts la psychométrie continue d'être influencée par l'héréspécifiques qui était celle de Yule, et que d'autre part ditarisme -- mais on ne pourrait le prouver qu'en analysant la littérature contemporaine, ce qui sort du cadre de notre étude.

La controverse et les intérêts sociaux

tion différentes chez Pearson et Yule étaient structurées Notre analyse a montré que les théories de l'associapar des intérêts cognitifs différents et que ces intérêts différents pouvaient s'expliquer par le rapport entre la ques, et par l'absence d'un rapport de ce type dans le qui poursuivait, sous sa direction, un programme de théorie statistique de Pearson et ses recherches eugénicas de Yule. Pearson devait presque uniquement son soutien au petit groupe de chercheurs étroitement liés recherche unifié en statistique, biométrie et eugénique. Yule réunit comme il le put le soutien de gens que n'enthousiasmait pas l'eugénique et dont le principal len institutionnel semble avoir été la Royal Statistical

vol. 49 (1954), 763.

89. L.A. GOODMAN et W.H. KRUSKAL, « Measures of Association for Cross Classifications », Journal of the American Statistical Association,

^{90.} Par exemple J.A. DAVIS, Elementary Survey Analysis, Prentice

Hall, Englewood Cliffs, N.J., 1971.
91. Par exemple N.J. CASTELLON, Jr., « On the Estimation of the Tetrachoric Correlation Coefficient », Psychometrica, vol. 31 (1966),

comment faire une sociologie de la statistique...

idéologie exprimant les intérêts d'une fraction spécifihypothétique. Dans cette section, j'examinerai les intérêts sociaux sur lesquels reposait l'eugénique en Grande-Grande-Bretagne. J'analyserai l'eugénique comme une que de la société britannique, et pas ceux des autres rêts du groupe G n'implique pas que tous les membres verse a peut-être trouvé ses fondements dans les intéêts sociaux de la structure sociale changeante en fractions. En procedant ainsi, je ne prétends pas expliparticulier. Pour faire une analogie avec la sociologie politique, dire que le parti politique P exprime les inté-Le stade final de notre analyse sera nécessairement Bretagne, ce qui m'amènera à suggérer que la controquer de façon causale les croyances d'individus pris en du groupe G, ou même sa majorité, votent pour P. Cela veut plutôt dire que la politique de P, si elle est mise en œuvre, améliorera la situation financière, le statut, le pouvoir, la sécurité, etc., de G. On peut prévoir que le raisonnement est fondamentalement structurel et non individuel. Donc, en examinant les relations éventuelles entre la recherche et les intérêts sociaux de l'eugénique, je ne veux pas dire que ces intérêts sont nécessaires et suffisants pour expliquer les travaux que le soutien apporté à P sera différent suivant qu'il s'agit ou non de membres de G, mais l'important est scientifiques et les croyances d'individus pris en particulier. Pearson, Yule et les autres statisticiens évoqués ici étaient des individus qui suivaient généralement des modèles de carrière complexes et en venaient souvent à prendre des positions très personnelles. Cependant, ils choisissaient leurs croyances et leurs attaches à partir non pas de rien, mais d'une situation historique et sociale. On peut espérer que l'étude de cette situation éclaire leurs choix, même si elle n'en fournit pas une

explication causale.

En Grande-Bretagne, la période située entre la fin du xviii siècle et le début du xix marqua le passage du premier capitalisme, celui du laisser-faire et de la

sement considérable du nombre, du rôle et de l'imporsédaient pas de capital mais se distinguaient de la classe c'est celle des « diplômés » membres des professions concurrence, à un capitalisme de monopole accompagné de son importante bureaucratie publique et privée. 'une des conséquences de cette transition fut l'accroistance de ce que Poulantzas appelle la « nouvelle petite bourgeoisie », ces travailleurs non manuels qui ne posouvrière par leur position privilégiée dans une situation de division du travail qui séparait de façon rigide et hiérarchique l'intellectuel du manuel 92. La fraction supéintellectuelles — médecins, scientifiques, ingénieurs, travailleurs sociaux, etc. — dont l'activité était légitimée par le fait qu'ils possédaient des connaissances accréditées tenues pour particulièrement importantes, et à l'accès strictement contrôlé. On peut considérer ce groupe comme un intermédiaire entre d'une part la classe des travailleurs manuels et d'autre part la bourdre, cette situation le mena à formuler ou adopter des geoisie et l'aristocratie. Comme on pourrait s'y attenidéologies qui soulignaient, d'une part, sa différence et sa supériorité par rapport à la classe des travailleurs rieure de cette classe est particulièrement intéressante manuels et, d'autre part, la valeur sociale des connaissances et du savoir-faire professionnels par rapport au simple fait de posséder des terres ou des capitaux.

L'eugénique était exactement ce genre d'idéologie. Pour les eugénistes, les différences entre travailleurs manuels et diplômés étaient dues à des différences héréditaires de capacités. Cela revenait à donner à la division entre travail manuel et travail intellectuel la force d'une division naturelle entre des espèces différentes d'individus. En même temps, les eugénistes faisaient une analyse des problèmes particuliers de la société capitaliste victorienne et edwardienne et, point très

^{92.} N. Poul.Antzas, Les Classes sociales dans le capitalisme d'aujourd'hui, Seuil, Paris.

a science telle qu'elle se fait

mination pour le programme eugénique. La politique sociale des eugénistes était « scientifique » au moins penprolétariat urbain, le « résidu ». Ils disaient de ce lique, le philanthrope et le prêtre réussiraient le mportant, de l'état de privation et d'agitation du lumgroupe que c'était celui des « inadaptés » dans leur orme extrême et en faisaient une cible privilégiée d'élidans sa façon d'insister sur le libre cours qu'il fallait donner aux connaissances et au savoir-faire des professions scientifiques. Là où avaient échoué l'homme polistatisticien, le médecin, le biologiste et le travailleur social 93

sion du capitalisme britannique, le sort de certains des élites traditionnelles n'en fut pas moins en partie souligner la primauté de la campagne sur la ville, de la que, de l'esthétique sur l'utilitaire. On peut effectivela réaction aristocrate antibourgeoise. Mais la position à s'accommoder des changements sociaux, d'autres n'y pourrait la prévoir dans ce genre de situation, serait de Raymond Williams; l'« idéal aristocratique » selon voyaient leur importance grandir par suite de l'expanindustriel en Grande-Bretagne atténua considérablement érodée. Alors que nombre de ses membres réussissaient varvenaient pas. La réaction de ces derniers, telle qu'on déployer des idées conservatrices anti-industrialistes, de culture sur la technologie, de l'organique sur l'atomiment interpréter ainsi plusieurs circonstances, par exemple: la tradition « culture et société » exposée par Perkin; le « socialisme chrétien » dont parle Levitas; la philosophie de l'idéalisme absolu; et la physique de Tandis que certains groupes (tels que les diplômés) autres se détériorait relativement. L'accommodement et le mariage entre la propriété terrienne et le capital Cambridge présentée par Wynne 94. 93. Cette argumentation est une version très condensée de D. MACKEN. IIE, « Eugenics in Britain », Social Studies of Science, vol. 6 (1976),

94. Raymond WILLIAMS, Culture and Society 1780-1950, Chatto and Windus, Londres, 1958; Harold PERKIN, The Origins of Modern English

comment faire une sociologie de la statistique..

aucune raison de défendre le « résidu » urbain, ni de ni évidemment d'être séduits par l'affirmation d'une geoise scientiste et interventionniste de l'eugénique n'avait pas grande chance de les séduire non plus. Bien Quelles positions peut-on prévoir de la part de ces groupes sur le problème de l'eugénique? Ils n'avaient nettre en question la division hiérarchique du travail, égalité intrinsèque générale. Néanmoins, la nature bourpes fondamentaux de l'eugénique, cette culture leur était étrangère. William Bateson, pionnier de la génélique et, sous de nombreux aspects, penseur conservaeur archétypique, exprimait sa répugnance à l'égard des valeurs petites-bourgeoises et du réformisme autoqu'ils ne trouvent rien à redire à la plupart des princisuffisant des eugénistes en écrivant:

res de la vertu moralisante ne sont pas vraiment essentiels Les faux cols, les relevés bancaires et les autres accessoià l'idéal eugénique.

Le genre de choses que je dis dans ces occasions [les discussions sur l'eugénique], c'est ce qu'aucun réformateur ne veut entendre, or les corbeaux de l'eugénique croassent pour avoir des réformes... 95, Je m'attendais donc à voir une tendance au soutien de l'eugénique de la part des professions intellectuelles montantes et une indifférence ou une répugnance à son égard de la part des adversaires du progrès bourgeois (bien que, comme je l'ai expliqué précédemment, cela

R.A. LEVITAS, « The Social Location of Ideas », Sociological Review, vol. 24 (1976), 545-557; B. WYNNE, « C.G. Barkla and the J. Phenomenon: A Case Study in the Sociology of Physics » (thèse de doctorat non Society, 1780-1880, Routledge and Kegan Paul, Londres, 1972, 237-252; subliée, University of Edinburgh, 1977).

375; lettre à M. Pease, 28 janvier 1925, réimprimé, ibid., 388. Sur le 95. W. BATESON, « Common-sense in Racial Problems », réimprimé conservatisme de Bateson, voir W. Coleman, « Bateson and Chromosomes: Conservative Thought in Science », Centaurus, vol. 15 (1970), 228-314. dans B. BATESON, William Bateson, Cambridge University Press, 1928

déterministe. Le raisonnement est structurel et non indi-L'Eugenics Education Society se composait presque exclusivement de diplômés, avec une prédominance de viduel). Telle fut en effet la situation dans l'ensemble. professeurs d'université et de médecins. Ses adversaivateurs de gauche, l'Église catholique et les défenseurs reste une corrélation escomptée et non une prévision es faisaient partie de groupes divers tels que les conserdes libertés individuelles traditionnelles %.

vaille avec sa tête » et dont les intérêts sont distincts à société post-capitaliste dirigée par une élite scientifique fesseur, Pearson le « méritocrate », le socialiste élitiste, Les premières étaient pour lui ignorantes et politiquement inconstantes. Les secondes manquaient de la comefficacement une société moderne 97. Son socialisme était proche de celui des fabiens. Il était favorable à une politique devant mener progressivement à une et administrative, bien que les propositions des fabiens d'un illogisme dangereux 98. Il prônait l'« enthousiasme pour l'étude » plutôt que pour le « mar-Revenons-en maintenant à nos deux protagonistes. le libre penseur positiviste peut être considéré comme in membre archétypique des professions intellectuelles montantes. Ses premiers essais montrent qu'il était pleinement conscient d'appartenir à cette « classe qui trapétence désintéressée, nécessaire pour administrer visant à étendre la démocratie politique lui parussent ché » 99. Il avait une conception évolutionniste et Pearson, fils d'un avocat en ascension qui devint proa fois de la classe ouvrière et des élites traditionnelles.

96. Voir FARRALL, op. cit., note 73; MacKeuzie, op. cit., note 93; G.R. SEARLE, Eugenics and Politics in Britain, 1900-1914, Noordhoff, Leyde, 1976.

97. Voir K. PEARSON, « Anarchy », The Cambridge Review, vol. 2 (1881), 268-270, et ses essais sur le socialisme dans « The Ethic of Free-

demy, vol. 37 (1890), 197-199. 99. Voir son essai du même nom dans « The Ethic of Freethought », 98. Voir son compte rendu des Fabian Essays in Socialism in The Acahought », Unwin, Londres, 1888.

comment faire une sociologie de la statistique...

tifique de l'eugénique avant de s'engager dans une appuyer l'action sociale. Son eugénisme était très sabien; il s'opposait à ceux qui voulaient aller trop loin action politique inconsidérée. Mais cela ne veut pas dire que son eugénisme était socialement neutre. Il s'en serorganise et dirige 100, » Cette minorité devait être la recherche de connaissances solides sur lesquelles et trop vite, et cherchait à fonder la respectabilité scienvait explicitement pour justifier par exemple les nécessaires différences de l'enseignement: « Il faut un système d'enseignement pour la masse, qui suit, entièrement distinct du système requis pour la minorité, qui essentiellement recrutée parmi les travailleurs intellecscientiste de la morale et fondait son épistémologie sur tuels et non parmi les manuels, car:

défendre la culture et le travail intellectuels, sont le résultat [...] les classes moyennes en Angleterre, qui sont là pour de la sélection faite à partir d'autres classes durant des générations et de mariages internes 101.

son, Yule était très discret sur ses conceptions sociales, ces d'information précises où puiser. Ce qui ressort, à En ce qui concerne Yule, j'ai surtout parlé jusqu'ici de l'« homme public », du « conseiller » en statistique, qui n'avait pas d'engagement spécifique très marqué. Mais il y avait un autre Yule. Contrairement à Pearpolitiques et philosophiques; on a donc peu de sourcompte par ceux qui le connaissaient bien et de quellique et conservateur. Major Greenwood écrivait ainsi à son sujet: « Politiquement, même dans le domaine mon avis, de ses lettres, des observations faites sur son ques rares passages de ses écrits, c'est qu'il était tout à la fois chaleureux et fondamentalement détaché, scep-

2p. cit., note 97.

^{100.} K. PEARSON, « Prefatory Essai : The Fonction of Science in the Modern State », Encyclopedia Britannica, 10° édition, Adam and Charles Black, Londres, 1902, vol. 8 des nouveaux tomes, XVI.

chercheur scientifique idéal comme quelqu'un qui se mise jusqu'à Yule. Faute de trouver un emploi suffiechniciens, et de donner des cours du soir à des « marquée par l'esprit d'entreprise » et « tournée vers es problèmes sociaux » de Pearson, Yule voyait le promène à travers le monde, libre de toute attache, de oute subvention, de tout engagement 105. Contre le elle parut rétrograder, du moins au début de sa vie. Il appartenait à une famille d'officiers de la vieille élite, durant l'essentiel de la période évoquée ici, de travailer dans un jury d'examen pour apprentis artisans et l avait une position radicalement différente de celle de l'ule défendait les conceptions antidarwiniennes et nutationnistes de J.C. Willis 104. Contre la science positivisme de Pearson, Yule voyait d'un œil suspect e culte de la mesure 106. Quant à sa position sociale, conctionnaires des Indes et orientalistes. Son frère et son oncle avaient reçu le titre de chevalier 107. Mais il ne semble pas que la richesse de la famille se soit transsamment rémunéré dans la statistique, il fut contraint, employés. Si la position sociale de Yule ne semble pas iniversitaire, c'est un conservateur dur et intransipearson. Contre le darwinisme orthodoxe de Pearson. des plusieurs questions scientifiques de portée politique, geant 102. » Plus tard, il se tourna vers la religion 103

102. Greenwood à Raymond Pearl, 19 août 1926, Pearl Papers, Ameican Philosophical Society, Philadelphie.

103. Yule à Greenwood, 2 février 1936. En possession de George

Conclusions of Dr. J.C. Willis, FRS », Philosophical Transactions of the Royal Society, Series B, vol. 213 (1924-1925), 21-87. Sur les conceptions 104. YULE, « A Mathematical Theory of Evolution based on the de WILLIS, voir son livre Age and Area, Cambridge University Press, 105. George Udny YULE, « The Wind bloweth where it Listeth »,

Cambridge Review, vol. 41 (1920), 184-186. 106. YULE, « Critical Notice », British Journal of Psychology, General Section, vol. 12 (1921-1922), 106-107.

107. Sur la famille de Yule, voir le Dictionary of National Biography

es au lieu de rester à l'écart), on peut voir peut-être oort éventuel entre une élite déclinante, un conservatisme général et une répugnance à l'égard de exemple de partager le sort des fabiens ou des eugénisavoir déterminé ses opinions (rien ne l'empêchait par lans sa carrière et ses croyances l'illustration d'un rap-'eugénique.

comment faire une sociologie de la statistique..

aucune position de pouvoir; nous pouvons donc être ils de directeur des Jardins royaux de Kew; lui-même ministère de l'Agriculture 109. Francis Ysidro own, dans le comté de Langford), mais cette famille stait particulièrement sur le déclin. Bien que cinquième plus assurés que ceux qui le soutenaient le faisaient par conviction. Hooker et Edgeworth avaient les mêmes antécédents que Yule, R.H. Hooker était fils et petiterait pas à grand-chose d'examiner la position sociale « membres des professions intellectuelles montantes » olutôt que comme des « membres de l'élite déclinante » écossaise, se fraya, grâce au système éducatif, un chees dont il devint une figure dominante 108), ce genre suivit une carrière plus modeste de fonctionnaire au Edgeworth appartenait à une vieille famille de l'aristoratie anglo-irlandaise (qui avait son siège à Edgeworth-Et les autres protagonistes de la querelle? Vu le caractère institutionnel des liens entre la statistique et 'eugénique au sein de l'école biométrique, cela n'avan-3ien que les étudiants de Pearson sur lesquels on a des nformations apparaissent généralement comme des ainsi David Heron qui, sorti d'une école de village de renseignement n'a pas grande importance. Les pargeait aucun établissement de recherche et n'avait les autres biométriciens en plus de celle de Pearson. min jusqu'au gouvernement et aux milieux universitaiisans de Yule nous intéressent plus, car Yule ne diri-

^{108.} E.S. PEARSON, op. cit., note 71.

G.U. YULE, « Reginald Hawthorn Hooker, MA », Journal of the Royal Statistical Society, vol. 107 (1944), 74-77.

Conclusion

Gentry de Burke, paraît plutôt se situer, en tant que fils tuelles des classes moyennes. Son cas (on peut penser que son poste dans la santé publique l'amena à renier ses premières prises de position eugénistes) illustre la fils d'un sixième fils, Edgeworth était le dernier descendant mâle du nom, et lorsqu'il hérita des biens immo-Greenwood, en revanche, bien que cité dans le Landed et petits-fils de médecins, dans les professions intelleccomplexité des rapports entre l'appartenance de classe biliers de la famille, ceux-ci étaient à l'abandon 110 et les convictions eugénistes.

L'une avait ses racines dans la position des diplômés cratiques telles que le fabianisme 111 et dans le mouvement eugéniste. L'autre s'enracina dans la situation des quels ses descendants en déclin 112) pour qui la moder-On peut résumer comme suit les hypothèses suggéées dans cette section: il semble que l'intelligentsia brielle trouva son expression dans des idéologies technonembres disparates de l'élite traditionnelle (parmi lesnisation représentait une menace. Cette constellation rouva son expression dans diverses formes de conservatisme, mais pas dans des idéologies scientistes telles que l'eugénique. On peut donc voir dans l'eugénique une idéologie exprimant les intérêts de certains secteurs annique des périodes victorienne et edwardienne ait eprésenté deux constellations d'intérêts distinctes. dont l'importance grandissait avec la modernisation: seulement de la société britannique,

apparaissent dans les travaux de Pearson et de Yule exprimaient des intérêts cognitifs différents; que ces intérêts cognitifs différents provenaient de deux façons aucun engagement marqué de cet ordre; et enfin que différentes de poser le problème : l'une était celle d'un eugénique et l'autre celle d'un statisticien qui n'avait 'eugénique elle-même réunissait les intérêts sociaux J'ai affirmé qu'on pouvait considérer que les deux tatisticien engagé dans un programme de recherche en upproches divergentes de la mesure de l'association qui

pose cette conclusion à titre d'essai seulement. J'espère Comme il n'existe que peu de recherches dans ce lomaine, notamment sur les éventuelles constellations d'intérêts suggérées dans la section précédente, je pronéanmoins avoir montré dans cet article que les « sciences dures » telles que la théorie mathématique des staistiques ne doivent pas être exclues a priori des analyses la théorie statistique en Grande-Bretagne. en termes d'intérêts sociaux,

férents se mêlèrent indirectement au développement de

'« entremise » de l'eugénique, des intérêts sociaux dif-

'exclusion des autres. On peut donc dire que, par

d'un secteur spécifique de la société britannique, à

^{110.} Voir J.M. KEYNES, « Francis Ysidro Edgeworth, 1845-1926 », Economic Journal, vol. 36 (1926), 140-153, et A.L. Bowley, « Francis sidro Edgeworth », Econometrica, vol. 2 (1934), 113-124.

^{111.} E.J. Hobsbawm, Labouring Men, Weinfeld and Nicolson, Lon-112. Voir également sur ce point R.A. LEVITAS, op. cit., note 94. Ires, 1968, 250-271; H. PERKIN, op. cit., note 94, 261-262.

